UNIVERSIDADE FEDERAL DE SERGIPE

CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA

DEPARTAMENTO DE COMPUTAÇÃO

Predição de Resultados em Partidas de Futebol com Base nos Atributos Individuais dos Jogadores em Escalações Iniciais: Um Estudo de Caso do FC Barcelona

Trabalho de Conclusão de Curso

Unaldo Santos Vasconcelos Neto

São Cristóvão – Sergipe

2026

UNIVERSIDADE FEDERAL DE SERGIPE

CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA

DEPARTAMENTO DE COMPUTAÇÃO

Unaldo Santos Vasconcelos Neto

Predição de Resultados em Partidas de Futebol com Base nos Atributos Individuais dos Jogadores em Escalações Iniciais: Um Estudo de Caso do FC Barcelona

Trabalho de Conclusão de Curso submetido ao Departamento de Computação da Universidade Federal de Sergipe como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Orientador(a): Rodolfo Botto de Barros Garcia

São Cristóvão – Sergipe

2026

Agradecimentos

Meu agradecimento mais profundo e sincero é para meus pais, Fernanda Gabriela e Willame Vasconcelos. Vocês sempre foram os que mais acreditaram nesta conquista, muitas vezes até mais do que eu mesmo. O apoio incondicional, os sacrifícios silenciosos, a dedicação diária e a confiança que nunca me faltaram foram essenciais para que eu chegasse até aqui. Esta realização também é de vocês, construída com esforço, amor e persistência ao longo de toda essa caminhada.

Ao meu irmão, Luís Miguel, deixo um agradecimento muito especial. Cuidar de você foi, para mim, um grande aprendizado. Mesmo de forma indireta, você me ensinou sobre maturidade, responsabilidade e compromisso, contribuindo de maneira significativa para a minha formação pessoal e humana.

À minha namorada, Jéssica Ellen, agradeço por estar ao meu lado durante todo esse processo. Obrigado pela paciência, pela compreensão, pelo apoio constante e, principalmente, por sempre me ouvir — inclusive nos momentos de reclamação. Sua presença tornou os desafios mais leves e os dias difíceis mais fáceis de enfrentar.

À minha avó Verleide, que infelizmente não pôde estar presente para viver este momento, deixo uma homenagem carregada de carinho e saudade. Tenho certeza de que estaria tão feliz e orgulhosa quanto meus pais. Seus ensinamentos e sua presença seguem vivos em minha memória e no meu coração.

Aos meus avós, Maria Edna e José Unaldo, agradeço pelo carinho, pelo incentivo e pelo apoio ao longo de toda a minha trajetória.

Ao Clube de Regatas do Flamengo, agradeço pelos momentos de alegria que ajudaram a tornar muitas noites de estudo mais leves e divertidas — mesmo que, em alguns momentos, tenha causado mais estresse do que os próprios estudos.

Aos meus amigos Ítalo, Marcelo, Paulo, Igor, Pedro, Vitor e Wesley meu muito obrigado pela amizade, pelo companheirismo e por estarem comigo do início ao fim da graduação. Compartilhar essa caminhada com vocês tornou essa etapa muito mais significativa.

Ao meu orientador, Rodolfo Botto, agradeço pela orientação, pela paciência e pela valiosa contribuição acadêmica ao longo deste trabalho. Sua dedicação foi fundamental para a realização deste projeto. Mesmo secando o Flamengo, deixo aqui meu reconhecimento e admiração pelo apoio oferecido durante toda esta etapa.

Por fim, agradeço a todos que, direta ou indiretamente, contribuíram para a realização deste momento tão importante da minha vida.

Aconteça o que acontecer, acontece.

(Spike Spiegel)

Resumo

Este trabalho investiga o uso de técnicas de Inteligência Artificial (IA) para prever resultados de partidas de futebol profissional, utilizando como preditores os atributos individuais dos jogadores presentes nas escalações iniciais. A metodologia consistiu na integração de múltiplas bases de dados heterogêneas, incluindo dados históricos de partidas e avaliações técnicas provenientes de bases de dados virtuais de desempenho. A abordagem proposta é avaliada por meio de um estudo de caso envolvendo partidas do FC Barcelona no período de 2009 a 2026. Foram avaliados oito algoritmos de aprendizado de máquina, abrangendo modelos lineares, técnicas de ensemble e redes neurais profundas.

Os resultados demonstram que a arquitetura de Redes Neurais Multilayer Perceptron (MLP) obteve o melhor desempenho, alcançando uma acurácia de 69,36% e um F1-Score de 80,61%. A análise de importância de variáveis identificou o mando de campo como o preditor individual mais relevante, seguido por atributos técnicos como precisão de passe, controle de bola e finalização. Experimentos de engenharia de *features* comprovaram que a agregação de atributos por média individual é capaz de reduzir o ruído e melhorar a generalização dos modelos em comparação ao uso de dados brutos de alta dimensionalidade. O estudo demonstra a viabilidade do uso de atributos de desempenho virtual para a predição de cenários esportivos reais, fornecendo uma abordagem aplicável ao suporte à tomada de decisão e à análise tática no futebol profissional.

Palavras-chave: futebol. inteligência artificial. aprendizado de máquina. atributos individuais. predição de resultados. estudo de caso.

Abstract

This work investigates the use of Artificial Intelligence (AI) techniques to predict professional football match outcomes, using the individual attributes of players in the starting lineups as predictors. The methodology consisted of integrating multiple heterogeneous databases, including historical match data and technical evaluations derived from virtual performance datasets. The proposed approach is assessed through a case study involving FC Barcelona matches from 2009 to 2026. Eight machine learning algorithms were evaluated, covering linear models, ensemble techniques, and deep neural networks.

The results show that the Multilayer Perceptron (MLP) neural network architecture achieved the best performance, reaching an accuracy of 69.36% and an F1-Score of 80.61%. Feature importance analysis identified home advantage as the most relevant individual predictor, followed by technical attributes such as passing accuracy, ball control, and finishing. Feature engineering experiments demonstrated that aggregating attributes through player-wise averages is able to reduce noise and improve model generalization when compared to the use of high-dimensional raw data. The study demonstrates the viability of using virtual performance attributes to predict real sporting scenarios, providing a robust approach for decision support and tactical analysis in professional football.

Keywords: football. artificial intelligence. machine learning. player attributes. match prediction. case study.

Lista de ilustrações

Figura 1 – Esquema conceitual da agregação no *Random Forest*. 22
Figura 2 – Esquema conceitual da agregação no *Random Forest*. 22
Figura 3 – Comparação entre Regressão Linear e Regressão Logística (SJöBERG, 2023). 23
Figura 4 – Exemplo de fronteira ótima de decisão (hiperplano) entre duas classes (GKIASTAS, 2022). 24
Figura 5 – Exemplo de rede neural *feedforward* (MLP)(GKIASTAS, 2022) 25
Figura 6 – Rede neural recorrente sincronizada, *many-to-many* (SJöBERG, 2023) . . . 26
Figura 7 – Estrutura de uma unidade LSTM (GKIASTAS, 2022) 27
Figura 8 – Exemplo de rede LSTM multicamada com 3 camadas (GKIASTAS, 2022) . 27
Figura 9 – Análise comparativa: Acurácia e F1-Score por modelo e experimento, e relação entre número de features e desempenho. 56
Figura 10 – Matriz de Confusão - MLP (Melhor Modelo) 57
Figura 11 – Matriz de Confusão - Random Forest 58
Figura 12 – Evolução temporal: Acurácia por temporada, relação com tamanho do treino e disparidade de desempenho Casa vs. Fora. 60

Lista de tabelas

Tabela 1 – Filtragem dos estudos relevantes 32
Tabela 2 – Comparação de desempenho entre melhor modelo deste trabalho e a literatura citada 38
Tabela 3 – Estrutura e volumetria do European Soccer Database 40
Tabela 4 – Estrutura e volumetria do Ultimate Soccer Dataset 40
Tabela 5 – Estrutura e volumetria do FIFA Official Dataset 41
Tabela 6 – Categorias de atributos por jogador 45
Tabela 7 – Estrutura consolidada do dataset final 47
Tabela 8 – Desempenho dos modelos no conjunto de teste 55
Tabela 9 – Comparação entre experimentos de representação de features 56
Tabela 10 – Análise de importância por categoria de atributos 59
Tabela 11 – Desempenho temporal incremental (Random Forest) 60

Lista de códigos

Código 1 – Remoção de duplicatas por chave composta 42
Código 2 – Identificação das partidas do FC Barcelona 43
Código 3 – Definição da variável alvo binária (vitória/não vitória) 44
Código 4 – Padronização da variável de mando de campo 44
Código 5 – Função de correspondência temporal entre temporada e versão FIFA 45
Código 6 – Imputação de valores ausentes pela mediana 45
Código 7 – Verificação de integridade e consistência do dataset 46
Código 8 – Distribuição da variável alvo 47
Código 9 – Distribuição das partidas por mando de campo 48
Código 10 – Pré-processamento essencial das features 50
Código 11 – Divisão estratificada em treino, validação e teste 50
Código 12 – Treinamento do modelo MLP 51
Código 13 – Função unificada de avaliação 52
Código 14 – Treinamento do modelo Random Forest 68
Código 15 – Treinamento do modelo Gradient Boosting 68
Código 16 – Treinamento do modelo SVM com kernel RBF 69
Código 17 – Treinamento do modelo de Regressão Logística 69
Código 18 – Treinamento do modelo MLP (rede neural) 69
Código 19 – Treinamento do modelo XGBoost 70
Código 20 – Treinamento do modelo LightGBM 70
Código 21 – Treinamento do modelo CatBoost 71
Código 22 – Preparação do dataset do Experimento 1 (atributos agregados) 72
Código 23 – Preparação do dataset do Experimento 2 (todos os atributos) 73
Código 24 – Preparação do dataset do Experimento 3 (médias por jogador) 73
Código 25 – Preparação do dataset do Experimento 4 (atributos-chave) 74
Código 26 – Treinamento e avaliação dos experimentos comparativos 75
Código 27 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 1/4 . . 76
Código 28 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 2/4 . . 77
Código 29 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 3/4 . . 77
Código 30 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 4/4 . . 78
Código 31 – Execução do experimento temporal com Random Forest 78
Código 32 – Cálculo de importância agregada por jogador a partir do Random Forest . . 79

Lista de abreviaturas e siglas

IA	Inteligência Artificial
ML	Machine Learning (Aprendizado de Máquina)
ANN	Artificial Neural Network (Rede Neural Artificial)
SVM	Support Vector Machine
RF	Random Forest
LR	Logistic Regression (Regressão Logística)
Acc	Acurácia do modelo de predição
$F1$	F1-Score, média harmônica entre precisão e revocação
$RMSE$	Root Mean Squared Error (Raiz do Erro Quadrático Médio)
MAE	Mean Absolute Error (Erro Absoluto Médio)
FIFA	Fédération Internationale de Football Association
UFS	Universidade Federal de Sergipe
DCOMP	Departamento de Computação

Lista de símbolos

$P(y\|X)$	Probabilidade condicional do resultado y dado os atributos X
$\sum$	Somatório
μ	Média aritmética
σ	Desvio padrão
θ	Parâmetros do modelo de aprendizado de máquina
∇	Operador gradiente usado em otimização

Sumário

1 Introdução . . . 14
1.1 Motivação . . . 15
1.2 Objetivos . . . 16
1.2.1 Objetivo Geral . . . 16
1.2.2 Objetivos Específicos . . . 16
1.3 Uso de Ferramentas de Inteligência Artificial no Desenvolvimento do Trabalho 16
1.4 Estrutura do TCC . . . 17

2 Fundamentação Teórica . . . 18
2.1 Análise de Desempenho e Bases de Dados . . . 18
2.2 Inteligência Artificial no Futebol . . . 20
2.2.1 Adoção de IA por Clubes e Organizações . . . 20
2.2.2 Representação Computacional de Jogadores e Equipes . . . 20
2.2.3 Técnicas de Inteligência Artificial no Futebol . . . 21
2.2.4 Árvores de Decisão e Random Forest . . . 21
2.2.5 Regressão Logística . . . 22
2.2.6 Support Vector Machines (SVM) . . . 23
2.2.7 Redes Neurais Artificiais (ANN, RNN, MLP, LSTM) . . . 24
2.2.8 Redes Neurais Recorrentes e Long Short-Term Memory (LSTM) . . . 25
2.3 Métricas de Avaliação de Modelos Preditivos . . . 27

3 Revisão Sistemática . . . 29
3.1 Questões de Pesquisa . . . 29
3.2 Estratégia de Busca e Seleção . . . 29
3.3 Critérios de Seleção . . . 31
3.3.1 Critérios de Inclusão . . . 31
3.3.2 Critérios de Exclusão . . . 31
3.4 Análise dos Resultados . . . 32
3.4.1 Quais métodos de Inteligência Artificial (IA) são utilizados para prever resultados de partidas de futebol? . . . 32
3.4.2 Quais métricas estatísticas são empregadas para medir o nível de certeza das previsões? . . . 33
3.4.3 Quais bases de dados públicas são utilizadas em trabalhos de predição de resultados? . . . 34
3.4.4 Como os atributos individuais e a escalação inicial são usados para prever resultados de partidas de futebol? . . . 35

3.4.5 Quais são os principais desafios da predição de resultados de futebol com base em atributos dos jogadores presentes nas escalações iniciais? . . . 36
3.5 Resultados dos Trabalhos Relacionados . . . 37
3.5.1 Síntese Comparativa . . . 38

4 Construção da Base de Dados . . . 39
4.1 Bases de Dados Originais . . . 39
4.2 European Soccer Database . . . 39
4.3 Ultimate Soccer Dataset (Baselight) . . . 40
4.4 FIFA Official Dataset (FIFA17–FIFA23) . . . 41
4.5 Preparação de Dados . . . 42
4.5.1 Tratamento de Redundâncias . . . 42
4.5.2 Resolução de Conflitos . . . 43
4.6 Construção do Dataset Específico do FC Barcelona . . . 43
4.6.1 Seleção e Filtragem de Partidas . . . 43
4.6.2 Definição da Variável Alvo . . . 43
4.6.3 Padronização da Variável Mando de Campo . . . 44
4.6.4 Integração de Atributos dos Jogadores . . . 44
4.6.5 Tratamento de Dados Ausentes . . . 45
4.6.6 Validação e Consistência . . . 46
4.7 Estrutura Final do Dataset . . . 46
4.8 Análise Exploratória Preliminar . . . 47
4.8.1 Distribuição da Variável Alvo . . . 47
4.8.2 Distribuição por Mando de Campo . . . 48
4.9 Considerações Finais do Capítulo . . . 48

5 Pipeline De Modelagem Preditiva . . . 49
5.1 Pré-processamento de Dados . . . 49
5.2 Divisão Estratificada dos Dados . . . 50
5.3 Treinamento dos Modelos . . . 51
5.4 Avaliação Padronizada . . . 51
5.5 Experimentos de Representação de Features . . . 52
5.6 Análise Temporal Incremental . . . 52
5.7 Análise de Importância de Atributos . . . 53

6 Resultados e Discussões . . . 54
6.1 Preparação e Análise Descritiva dos Dados . . . 54
6.1.1 Desempenho Comparativo dos Modelos . . . 54
6.1.2 Experimentos de Representação de *Features* . . . 55
6.1.3 Análise Visual e Matrizes de Confusão . . . 57

6.1.4 Análise de Importância de Features 58
6.1.5 Análise Temporal: Evolução do Desempenho por Temporada 59

7 Conclusão 62
7.1 Viabilidade da Predição com Atributos Individuais 63
7.2 Superioridade de Modelos Não Lineares 63
7.3 Determinantes Preditivos do Desempenho 63
7.4 Recomendações Metodológicas 64
7.5 Trabalhos Futuros 64

Referências 65

Apêndices 67

APÊNDICE A Códigos completos do treinamento dos modelos 68
A.1 Random Forest 68
A.2 Gradient Boosting 68
A.3 SVM 69
A.4 Regressão Logística 69
A.5 MLP (Rede Neural) 69
A.6 XGBoost 70
A.7 LightGBM 70
A.8 CatBoost 71

APÊNDICE B Experimentos comparativos de representação de features 72
B.1 Experimento 1: Atributos agregados 72
B.2 Experimento 2: Todos os atributos 73
B.3 Experimento 3: Médias por jogador 73
B.4 Experimento 4: Atributos-chave 74
B.5 Protocolo de treinamento e avaliação dos experimentos 75

APÊNDICE C Validação temporal incremental (*Walk-Forward*) 76
C.1 Função do procedimento temporal 76
C.2 Execução do experimento temporal 78

APÊNDICE D Importância agregada por jogador 79

1
Introdução

O futebol é o esporte mais popular do mundo, envolvendo bilhões de torcedores e movimentando grandes investimentos financeiros, técnicos e científicos, de acordo com dados de uma das maiores distribuidoras de materiais esportivos do Brasil, a **Penalty**[1]. Nas últimas décadas, a aplicação de métodos quantitativos no futebol tem se expandido de forma significativa. Entretanto, a análise sistemática do jogo remonta à metade do século XX, com os estudos notacionais pioneiros de Reep e Pollard (1971), que buscaram quantificar a influência da habilidade e do acaso nos resultados esportivos.

Com o avanço computacional, essas abordagens evoluíram de distribuições estatísticas simples para o uso contemporâneo de algoritmos de aprendizado de máquina aplicados à predição de resultados e à análise de desempenho esportivo (HEIJBOER, 2022; GKIASTAS, 2022). Atualmente, o campo de *sports analytics* consolidou-se por meio da adoção de modelos de maior complexidade, integrando técnicas de modelagem preditiva, análise de desempenho e suporte à decisão.

Essa evolução é sustentada por frameworks metodológicos modulares que abrangem desde a compreensão do domínio esportivo até a modelagem e avaliação sistemática de modelos preditivos, conforme estruturado por Bunker e Thabtah (2019).

Dentro desse cenário, um dos desafios enfrentados por treinadores e analistas está relacionado à escolha da escalação ideal para cada partida. Essa decisão envolve múltiplos fatores técnicos, físicos, mentais e táticos, os quais impactam diretamente o desempenho coletivo da equipe. Além disso, a **filosofia de jogo do treinador** exerce influência significativa nesse processo: um técnico de perfil mais defensivo tende a priorizar zagueiros altos e fortes, linhas compactas e laterais com maior capacidade de marcação; já um treinador ofensivo pode optar por atacantes rápidos, meias criativos e maior número de jogadores no setor de ataque. Outros

[1] <https://www.penalty.com.br/blog/post/os-esportes-mais-populares-do-mundo?srsltid=AfmBOooaleNdRvpFZbWY5EedMiS160cEUoULyL8qCjSWLAdpt0>

estilos podem valorizar, por exemplo, goleiros com boa saída de bola com os pés, zagueiros com qualidade no passe, ou centroavantes de grande porte físico e boa finalização. As **características individuais** — como velocidade, resistência, leitura de jogo, impulsão, precisão no passe ou finalização — tornam-se, assim, determinantes para a composição do time titular. Outro aspecto relevante é a **forma de jogo do adversário**, que pode levar a ajustes estratégicos na escalação para neutralizar pontos fortes do oponente ou explorar fragilidades específicas. Tradicionalmente, essa escolha é feita de maneira empírica, com base na experiência e observação dos profissionais envolvidos no dia a dia, durante os treinos técnicos e táticos. Com tudo que foi escrito, o avanço das técnicas de Inteligência Artificial (IA) e Aprendizado de Máquina (ML) tem possibilitado o desenvolvimento de modelos preditivos que analisam variáveis complexas e oferecem suporte à tomada de decisão, auxiliando na definição da escalação inicial que maximize as chances de a equipe alcançar a vitória.

A proposta deste trabalho é baseada na hipótese de que modelos computacionais inteligentes são capazes de prever resultados em partidas de futebol com base nos atributos individuais dos jogadores presentes nas escalações iniciais. Com isso, análises dos 11 jogadores titulares e suas habilidades técnicas, características físicas e desempenhos recentes podem fornecer informações suficientes para estimar, com certo grau de confiabilidade, o desfecho de uma partida de futebol.

Neste trabalho, a abordagem proposta é investigada por meio de um estudo de caso envolvendo o FC Barcelona, considerando partidas disputadas entre 2009 e 2026. A escolha desse recorte permite avaliar o método em um cenário realista, com histórico amplo e consistente de dados, ao mesmo tempo em que mantém o foco na análise metodológica da predição baseada em atributos individuais e escalações iniciais.

1.1 Motivação

O uso de Inteligência Artificial no futebol ainda é incipiente quando comparado a outras áreas como finanças, marketing ou saúde. Apesar do avanço das análises táticas e do uso de estatísticas, há uma lacuna relevante no emprego de modelos preditivos focados especificamente na relação entre escalação inicial, atributos individuais dos jogadores e o resultado final de uma partida. A possibilidade de quantificar e prever, com apoio de algoritmos, o impacto de diferentes combinações de atletas é de grande interesse para comissões técnicas, clubes e até mesmo para pesquisadores da área. Além disso, compreender quais variáveis mais influenciam o desempenho em campo pode contribuir para a evolução do treinamento, do planejamento de elenco e de estratégias de jogo. Essa relevância, somada ao crescimento do acesso a bases de dados esportivas e ao poder computacional disponível, reforça a importância desta pesquisa.

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver uma abordagem preditiva baseada em Inteligência Artificial capaz de estimar o resultado de partidas de futebol a partir da escalação inicial e dos atributos individuais dos jogadores.

1.2.2 Objetivos Específicos

- Realizar uma revisão sistemática da literatura sobre o uso de IA na predição de resultados de partidas de futebol;
- Identificar os principais métodos computacionais utilizados para esse tipo de predição;
- Investigar quais métricas estatísticas são aplicadas para avaliação da acurácia dos modelos preditivos;
- Levantar e analisar as bases de dados públicas mais utilizadas nos estudos da área;
- Compreender como atributos individuais e escalações iniciais são estruturados e utilizados nos modelos;
- Implementar um protótipo de modelo preditivo aplicado às escalações de futebol, utilizando as metodologias citadas neste trabalho.
- Identificar lacunas, limitações e desafios enfrentados por abordagens atuais;

1.3 Uso de Ferramentas de Inteligência Artificial no Desenvolvimento do Trabalho

Durante o processo de elaboração deste Trabalho de Conclusão de Curso, utilizei ferramentas de Inteligência Artificial generativa com diferentes finalidades, dentre elas, correção e aprimoramento textual, auxiliando na clareza e coesão da redação acadêmica.

Além disso, foi utilizado o *notebook LLM* (Large Language Models), que auxiliou na interpretação e elaboração de resumos de artigos científicos, na localização de termos, na redação da fundamentação teórica e na condução da revisão sistemática da literatura. Dessa forma, essas ferramentas não substituíram a análise crítica do pesquisador, mas serviram como recursos complementares para otimizar o processo de investigação, organização e produção científica.

1.4 Estrutura do TCC

Este trabalho está organizado da seguinte forma: o Capítulo 1 apresenta a introdução, motivação e objetivos. O Capítulo 2 discute a fundamentação teórica. O Capítulo 3 descreve a revisão sistemática da literatura. O Capítulo 4 detalha a construção da base de dados. O Capítulo 5 apresenta o pipeline de modelagem preditiva. O Capítulo 6 discute os resultados obtidos. Por fim, o Capítulo 7 apresenta as conclusões e trabalhos futuros.

2

Fundamentação Teórica

Este capítulo apresenta os conceitos fundamentais que embasam o desenvolvimento desta pesquisa, abordando a análise de desempenho no futebol, a avaliação de jogadores por atributos, a estruturação de dados para uso em modelos preditivos e as principais técnicas de Inteligência Artificial (IA) aplicadas ao contexto futebolístico.

2.1 Análise de Desempenho e Bases de Dados

Historicamente, a identificação e avaliação de talentos no futebol são realizadas por meio da observação direta de atletas por olheiros e treinadores. Esse processo, conhecido como *scouting*, envolve a análise subjetiva de aspectos técnicos, físicos, táticos e comportamentais de jogadores.

A tentativa de quantificar o desempenho no futebol, entretanto, não é recente. Trabalhos pioneiros como o de Reep e Pollard (1971) já buscavam compreender a influência relativa da habilidade e do acaso nos resultados esportivos por meio de sistemas notacionais manuais, estabelecendo as bases da análise estatística aplicada ao esporte.

O processo tradicional de *scouting* no futebol, baseado em observação direta por olheiros e treinadores, é amplamente documentado na literatura. Rein e Memmert (2016) apontam que a análise tática de alto nível era, até recentemente, limitada a dados observacionais simplificados, que descartavam grande parte da informação contextual disponível — um viés inerente ao *scouting* manual. Com o avanço das tecnologias de rastreamento e sensores, tornou-se possível capturar dados mais ricos e automatizados; contudo, o volume crescente de informações passou a exigir infraestrutura computacional adequada e modelos teóricos robustos para uma análise eficaz (REIN; MEMMERT, 2016).

Nesse contexto de crescente complexidade informacional, a seleção de jogadores e a formação de equipes configuram-se como um problema de decisão multicritério, no qual diversos

atributos técnicos, físicos e táticos devem ser avaliados simultaneamente. Para lidar com a subjetividade inerente a esse processo, abordagens baseadas em sistemas de inferência fuzzy têm sido propostas na literatura, permitindo modelar critérios qualitativos de forma estruturada e quantitativa (TAVANA et al., 2013).

A seleção de jogadores e a formação de equipes representam um desafio multifacetado, no qual diversos critérios devem ser considerados. Treinadores analisam os atletas sob múltiplos aspectos, que abrangem desde condições físicas até mentais. Para isso, são empregados parâmetros que incluem avaliações qualitativas e, principalmente, quantitativas, como as habilidades, estatísticas de desempenho, aptidão física, fatores psicológicos e histórico de lesões dos jogadores (ABIDIN, 2021).

A quantificação do desempenho tem sido aprimorada por meio de sistemas eletrônicos esportivos, como o *Hit/it Assistant*, que mensuram controle, técnica, tempo de reação, velocidade, agilidade, coordenação e habilidades de controle de ambiente. As avaliações dos treinadores, por sua vez, são corroboradas por dezoito critérios estabelecidos na literatura, servindo como padrão ouro na análise de jogadores (ABIDIN, 2021).

A construção de conjuntos de dados de mundo real é crucial para a análise aprofundada no futebol. Esses conjuntos incluem atributos individuais e de equipe, além de informações pré-jogo e outras métricas relacionadas ao desempenho (GKIASTAS, 2022). Plataformas como o *SofaScore* têm se destacado ao traduzir cerca de 1.500 eventos distintos ocorridos em cada partida em dados numéricos, englobando estatísticas como posse de bola, passes, duelos, desarmes e corridas (GKIASTAS, 2022, p. 46).

Para enriquecer a análise, são criadas variáveis adicionais. Um exemplo é a variável fictícia `home_fixture`, que indica se o jogo é disputado no campo do time do jogador (casa) ou fora (visitante), impactando diretamente o desempenho (GKIASTAS, 2022, p. 50–51). O histórico de lesões também é um fator crítico, sendo coletado manualmente e transformado em atributos como `after_injury` (indicando o primeiro jogo pós-lesão), `injury_days` (número de dias ausentes) e `injury_type` (tipo de lesão) (GKIASTAS, 2022, p. 51).

Além das estatísticas de campo, as habilidades dos jogadores, como drible, mentalidade, defesa, poder de chute, velocidade e resistência, são quantificadas e registradas em videogames como o *FIFA*. A partir dessas informações, podem ser criadas novas características, como o `fifa_rating` (classificação média de habilidades) e o `fifa_potential` (potencial de melhoria) (GKIASTAS, 2022, p. 51–52).

Métricas avançadas, como os gols esperados (xG) e os gols reais (aG), são utilizadas para uma avaliação mais precisa do desempenho dos jogadores, oferecendo uma perspectiva mais realista das oportunidades e concretizações em campo. Para uma análise detalhada, são empregados os termos gols esperados por jogo (xGg) e gols reais por jogo (aGg) (MALIKOV; KIM, 2024).

A extração e engenharia de características adicionais, como eficiência de pontuação, habilidades de criação de jogadas, comportamento disciplinar e outras métricas avançadas, enriquecem ainda mais o conjunto de dados (MALIKOV; KIM, 2024).

A disponibilidade massiva de dados sobre futebol é evidente em bases como a *European Soccer Database*, disponível no *Kaggle*, que contém informações de mais de 25.000 jogos de futebol de onze competições, abrangendo mais de doze anos e cinco fontes de informação (HEIJBOER, 2022, p. 7). Esta base inclui eventos ocorridos durante as partidas, como gols, chutes a gol e para fora, cruzamentos, posse de bola, faltas e cartões (HEIJBOER, 2022, p. 7).

As classificações do *FIFA*, inclusive, têm se mostrado uma característica altamente informativa para previsões, superando outras métricas relacionadas (HEIJBOER, 2022, p. 2). Outro exemplo é o conjunto de dados *SoFIFA*, publicado anualmente, que abrange a maioria dos jogadores de futebol adultos do mundo, com suas pontuações em diversas habilidades e informações contratuais (NOURAIE; ESLAHCHI; BACA, 2023).

Em síntese, os dados utilizados para análise preditiva no futebol geralmente englobam atributos de jogadores, atributos de equipe e estatísticas de partida (SJöBERG, 2023, p. 36).

2.2 Inteligência Artificial no Futebol

2.2.1 Adoção de IA por Clubes e Organizações

Diversos clubes ao redor do mundo têm investido em ciência de dados e IA para obter vantagem competitiva. Casos como o Liverpool FC, o Brentford FC e o FC Midtjylland são frequentemente citados como pioneiros na utilização de modelos preditivos para *scouting*, análise de desempenho e tomada de decisão (ABIDIN, 2021).

Além disso, empresas como *StatsBomb*, *Wyscout* e *Instat* fornecem plataformas completas de análise tática e estatística, integrando dados em tempo real e suporte a decisões técnicas.

2.2.2 Representação Computacional de Jogadores e Equipes

Para que seja possível utilizar dados de futebol em modelos computacionais, é necessário transformá-los em vetores numéricos representativos. Isso é feito associando a cada jogador um vetor de atributos, que pode ser utilizado individualmente ou agregado para representar uma equipe.

A escalação inicial de uma equipe, por exemplo, pode ser representada pela média ou soma dos atributos dos 11 jogadores titulares. Também é comum calcular diferenças entre equipes mandante e visitante, o que auxilia na redução da dimensionalidade do modelo (HEIJBOER, 2022).

Outros dados derivados incluem:

- Média de idade, altura e peso dos titulares;
- Número de alterações em relação à última formação;
- Frequência de utilização dos jogadores;
- Avaliações médias da equipe;

2.2.3 Técnicas de Inteligência Artificial no Futebol

A aplicação de técnicas de Inteligência Artificial (IA) no futebol tem se mostrado uma ferramenta valiosa para a análise e predição de resultados, formação de equipes e seleção de jogadores. Dentre as diversas abordagens de IA, destacam-se algoritmos de aprendizado de máquina como Árvores de Decisão, *Random Forest*, Regressão Logística, *Support Vector Machines* (SVM) e Redes Neurais Artificiais (ANN), cada um com suas particularidades e aplicações no contexto esportivo.

2.2.4 Árvores de Decisão e Random Forest

As **Árvores de Decisão (DT)** constituem uma das técnicas mais utilizadas em problemas de classificação e regressão, devido à sua estrutura hierárquica e elevada interpretabilidade (ABIDIN, 2021). O modelo organiza o processo decisório em um nó raiz, nós internos associados a condições sobre atributos, e folhas que representam os rótulos de classe ou valores preditos, permitindo a modelagem explícita de regras de decisão (SJöBERG, 2023).

Do ponto de vista teórico, o funcionamento das árvores de decisão fundamenta-se na partição recursiva do espaço de atributos, tendo como principal referência o algoritmo *CART* (*Classification and Regression Trees*), proposto por Breiman et al. (BREIMAN et al., 1984). Esse algoritmo emprega divisões binárias sucessivas, aplicáveis tanto a variáveis contínuas quanto discretas, com o objetivo de maximizar a homogeneidade dos nós resultantes. Para esse fim, são utilizadas métricas de impureza, como o índice de *Gini* (Equação 2.1) ou a entropia (Equação 2.2).

$$Gini(t) = 1 - \sum_{i=1}^{C} p_i^2 \qquad (2.1)$$

$$Entropia(t) = -\sum_{i=1}^{C} p_i \log_2(p_i) \qquad (2.2)$$

Embora apresentem vantagens como simplicidade e interpretabilidade, árvores de decisão individuais são sensíveis a variações nos dados de treinamento, o que pode resultar em modelos com alta variância. Para contornar essa limitação, Breiman introduziu o algoritmo ***Random Forest*** **(RF)** (BREIMAN, 2001), uma técnica de aprendizado em conjunto baseada na construção de múltiplas árvores independentes a partir de amostras geradas com reposição (*bootstrap*) e subconjuntos aleatórios de atributos.

O algoritmo constrói diversas árvores independentes a partir de amostras geradas com reposição (*bootstrap*) e subconjuntos de atributos, o que reduz a variância e evita sobreajuste (GKIASTAS, 2022). A predição final resulta da agregação das árvores: por voto majoritário no caso de classificação (Equação 2.5) ou pela média no caso de regressão (Equação 2.6). Essa combinação é ilustrada na Figura 2, em que múltiplas árvores contribuem para o resultado final (SJöBERG, 2023).

$$\hat{y} = \text{mode}\left(\{h_b(\mathbf{x})\}_{b=1}^{B}\right) \tag{2.3}$$

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} h_b(\mathbf{x}) \tag{2.4}$$

Exemplo conceitual: B árvores $\longrightarrow$ agregação (voto/média) $\longrightarrow$ predição final.

Figura 1 – Esquema conceitual da agregação no *Random Forest*.

$$\hat{y} = \text{mode}\left(\{h_b(\mathbf{x})\}_{b=1}^{B}\right) \tag{2.5}$$

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} h_b(\mathbf{x}) \tag{2.6}$$

Exemplo conceitual: B árvores $\longrightarrow$ agregação (voto/média) $\longrightarrow$ predição final.

Figura 2 – Esquema conceitual da agregação no *Random Forest*.

2.2.5 Regressão Logística

A **Regressão Logística** é um modelo de classificação que prediz probabilidades ao estimar coeficientes para variáveis independentes e aplicar a função logística para transformar os valores em probabilidades entre 0 e 1 (HEIJBOER, 2022).

Entre suas vantagens estão a velocidade, a interpretabilidade e a análise da importância dos atributos com base nos coeficientes. Embora seja originalmente binária, a regressão logística pode ser estendida para classificação multiclasse utilizando estratégias como *One-vs-Rest* ou *One-vs-One* (SJöBERG, 2023). A Regressão Logística pode ser entendida como um “parente

próximo" da Regressão Linear, diferenciando-se principalmente pelo fato de ser utilizada para classificação em vez de predição contínua (SJöBERG, 2023).

$$y = \frac{1}{1 + e^{-z}} \tag{2.7}$$

Enquanto a Regressão Linear estima valores em uma escala contínua, a Regressão Logística transforma a combinação linear das variáveis em probabilidades no intervalo (0,1) por meio da função sigmoide. A função logística é definida pela Equação 2.7, sendo y a probabilidade prevista e z a combinação linear dos atributos do modelo.

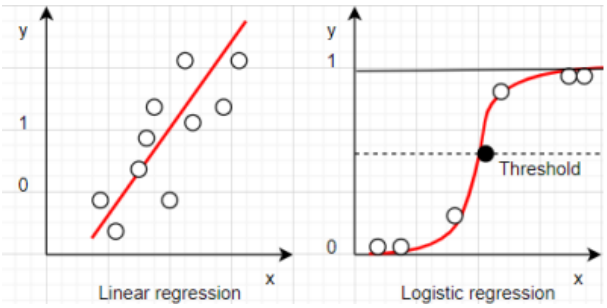

Figura 3 – Comparação entre Regressão Linear e Regressão Logística (SJöBERG, 2023).

2.2.6 Support Vector Machines (SVM)

As ***Support Vector Machines*** **(SVM)** constituem uma classe de algoritmos supervisionados amplamente utilizados em tarefas de classificação e regressão, fundamentados na construção de hiperplanos ótimos para a separação de classes em espaços de alta dimensão. A formulação original do método foi proposta por Cortes e Vapnik (1995), estabelecendo como objetivo central a maximização da margem entre os exemplos mais próximos de cada classe, conhecidos como vetores de suporte.

Essa propriedade torna o classificador particularmente robusto em cenários com sobreposição entre classes e ruído nos dados, características frequentes em problemas de predição esportiva, como a análise de desempenho e a previsão de resultados no futebol (GKIASTAS, 2022; ABIDIN, 2021).

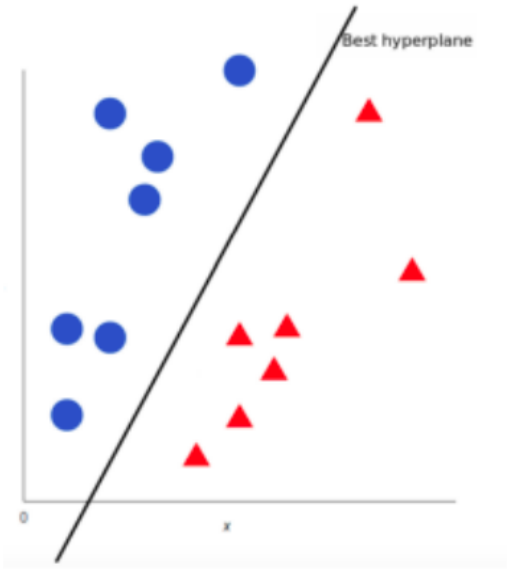

Figura 4 – Exemplo de fronteira ótima de decisão (hiperplano) entre duas classes (GKIASTAS, 2022).

Formalmente, o problema de otimização resolvido pelo SVM pode ser descrito como:

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{sujeito a } y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1, \ \forall i \tag{2.8}$$

onde $\mathbf{x}_i$ representa os vetores de entrada, $y_i \in \{-1, 1\}$ são os rótulos de classe, $\mathbf{w}$ é o vetor normal ao hiperplano e b o termo de viés. Essa formulação visa maximizar a margem de separação entre as classes, contribuindo para uma melhor capacidade de generalização do modelo.

A função de decisão associada ao classificador pode ser expressa como:

$$f(\mathbf{x}) = b + \sum_i \alpha_i y_i \mathbf{x}_i^T \mathbf{x} \tag{2.9}$$

em que α_i são os multiplicadores de Lagrange, responsáveis por identificar os vetores de suporte relevantes para a definição da fronteira de decisão.

2.2.7 Redes Neurais Artificiais (ANN, RNN, MLP, LSTM)

As **Redes Neurais Artificiais (ANN)** simulam o comportamento de neurônios humanos, com pesos ajustáveis e funções de ativação que determinam a saída de cada unidade (GKIASTAS, 2022). Possuem camadas de entrada, ocultas e de saída, sendo treinadas por propagação direta e ajuste de pesos por retropropagação de erro (ABIDIN, 2021). Um exemplo clássico de ANN é o

***Multilayer Perceptron* (MLP)**, que organiza os neurônios em camadas totalmente conectadas, conforme ilustrado na Figura 5.

A ativação de um neurônio em um MLP é calculada como:

$$g = \sum_i w_i x_i \tag{2.10}$$

onde w_i representa o peso da conexão e x_i a entrada correspondente. Essa soma é passada por uma função de ativação não-linear, tipicamente a sigmoide:

$$\sigma(x) = \frac{1}{(1 + e^{-x})} \tag{2.11}$$

O ajuste dos pesos é realizado via retropropagação:

$$w_{ij}(t+1) = w_{ij}(t) + \eta \frac{\partial C}{\partial w_{ij}} \tag{2.12}$$

com η sendo a taxa de aprendizado e C a função de custo.

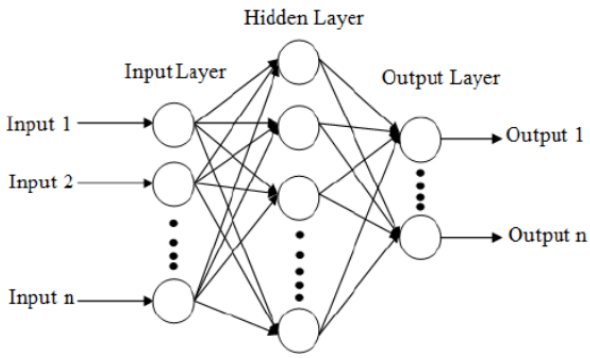

Figura 5 – Exemplo de rede neural *feedforward* (MLP)(GKIASTAS, 2022)

2.2.8 Redes Neurais Recorrentes e Long Short-Term Memory (LSTM)

A análise de séries temporais no contexto esportivo demanda modelos capazes de capturar dependências sequenciais ao longo do tempo. As **Redes Neurais Recorrentes (RNN)** atendem a esse requisito ao incorporarem mecanismos de memória por meio de conexões recorrentes, nas quais a saída de uma célula é retroalimentada ao seu próprio estado anterior, permitindo o processamento de sequências temporais (SJöBERG, 2023). A Figura 6 ilustra uma arquitetura RNN do tipo *many-to-many*.

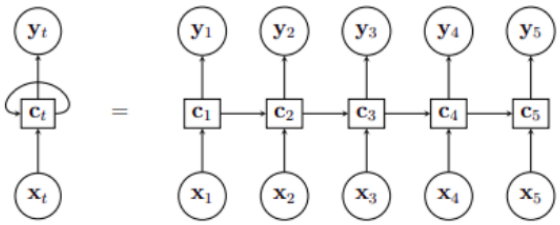

Figura 6 – Rede neural recorrente sincronizada, *many-to-many* (SJöBERG, 2023)

Apesar de sua capacidade de modelar sequências, RNNs tradicionais apresentam limitações relacionadas ao problema do gradiente evanescente, que dificulta o aprendizado de dependências de longo prazo. Para superar essa limitação, Hochreiter e Schmidhuber (1997) propuseram a arquitetura ***Long Short-Term Memory* (LSTM)**, que introduz um mecanismo de memória explícita controlado por portas de entrada, saída e esquecimento, regulando o fluxo de informação ao longo do tempo.

Essas características tornam as LSTM particularmente adequadas para aplicações em análise de desempenho esportivo, como o acompanhamento da evolução técnica e física de jogadores ao longo de múltiplas partidas ou temporadas, conforme explorado em estudos recentes de predição no futebol (GKIASTAS, 2022; SJöBERG, 2023).

O estado interno da célula c_t^j e a saída h_t^j de uma unidade LSTM são definidos pelas seguintes equações:

$$h_t^j = o_t^j \tanh(c_t^j) \tag{2.13}$$

$$c_t^j = f_t^j c_{t-1}^j + i_t^j \tilde{c}_t^j \tag{2.14}$$

$$\tilde{c}_t^j = \tanh(W_c x_t + U_c h_{t-1}^j) \tag{2.15}$$

$$o_t^j = \sigma(W_o x_t + U_o h_{t-1}^j + V_o c_t^j) \tag{2.16}$$

$$f_t^j = \sigma(W_f x_t + U_f h_{t-1}^j + V_f c_{t-1}^j) \tag{2.17}$$

$$i_t^j = \sigma(W_i x_t + U_i h_{t-1}^j + V_i c_{t-1}^j) \tag{2.18}$$

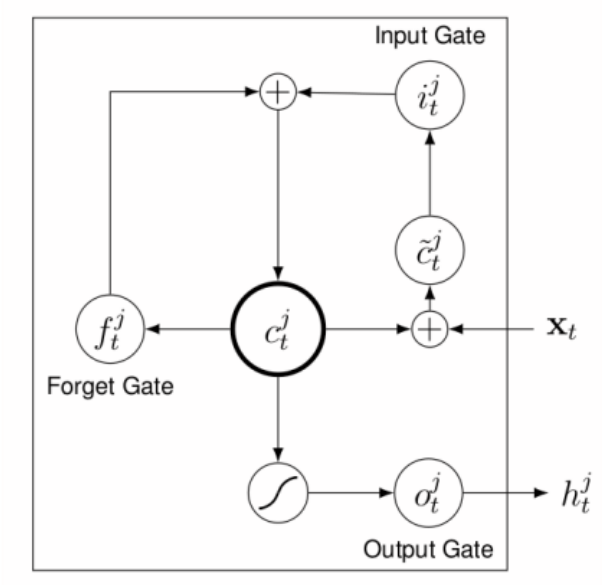

Figura 7 – Estrutura de uma unidade LSTM (GKIASTAS, 2022)

Finalmente, redes LSTM multicamadas, como mostrado na Figura 8, podem capturar dependências temporais complexas em várias camadas.

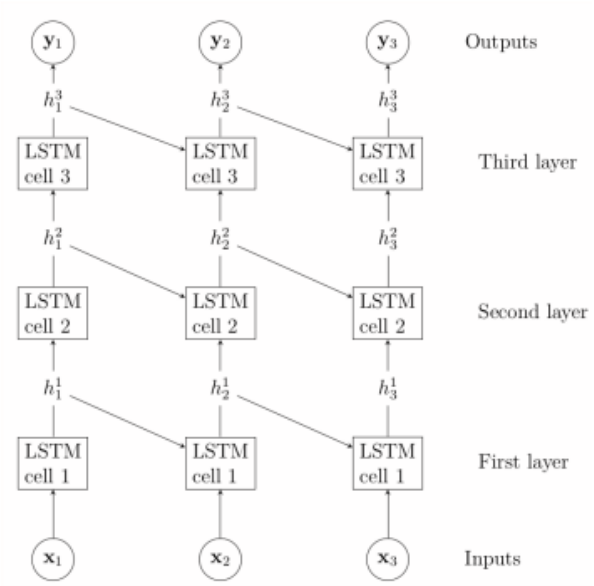

Figura 8 – Exemplo de rede LSTM multicamada com 3 camadas (GKIASTAS, 2022)

2.3 Métricas de Avaliação de Modelos Preditivos

A eficácia dos modelos de IA é medida por meio de métricas estatísticas que avaliam sua capacidade de prever corretamente os resultados. As métricas variam conforme o tipo de problema: classificação (vitória, empate, derrota) ou regressão (gols esperados, desempenho individual).

A avaliação dos modelos preditivos deste trabalho é realizada por meio de métricas clássicas de classificação, adequadas ao problema de prever o resultado de partidas de futebol em termos de vitória ou não vitória. As principais métricas utilizadas são a Acurácia, a Precisão, o Recall, o F1-Score e a Matriz de Confusão, cada uma medindo um aspecto distinto do desempenho do classificador.

- **Acurácia**: mede a proporção total de previsões corretas em relação ao número total de exemplos avaliados. Formalmente, corresponde à razão entre o número de acertos do modelo e o total de instâncias. Essa métrica fornece uma visão geral do desempenho, mas pode ser pouco informativa em cenários com classes desbalanceadas, como ocorre no futebol, onde empates são menos frequentes.
- **Precisão** (*Precision*): indica, entre todas as instâncias que o modelo classificou como positivas (por exemplo, vitórias), qual proporção está realmente correta. Essa métrica avalia a confiabilidade das previsões positivas e é especialmente relevante quando falsos positivos devem ser evitados.
- **Recall** (ou sensibilidade): mede a capacidade do modelo de identificar corretamente as instâncias positivas reais. Em outras palavras, representa a proporção de vitórias reais que foram corretamente detectadas pelo classificador. Essa métrica é importante quando o custo de deixar de identificar um caso positivo (falso negativo) é elevado.
- **F1-Score**: corresponde à média harmônica entre a precisão e o recall, fornecendo uma medida única que equilibra ambas. Essa métrica é particularmente adequada em problemas com classes desbalanceadas, pois penaliza modelos que apresentam bom desempenho em apenas uma dessas duas medidas.
- **Matriz de Confusão**: consiste em uma tabela que apresenta a distribuição das previsões corretas e incorretas do modelo, organizadas em verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos. Essa representação permite uma análise detalhada dos tipos de erro cometidos pelo classificador e auxilia na interpretação prática do seu comportamento.

A métrica F1-Score, em especial, é importante em contextos com classes desbalanceadas, como é o caso dos empates no futebol, que ocorrem com menor frequência (HEIJBOER, 2022; GKIASTAS, 2022).

3

Revisão Sistemática

Para a realização desta revisão bibliográfica, foi adotado o método de Mapeamento Sistemático da Literatura (*Systematic Literature Mapping* – SLM), conforme proposto por Petersen et al. (PETERSEN et al., 2008). Este método permite obter uma visão abrangente e estruturada sobre o estado da arte de uma determinada área de pesquisa, por meio da definição de questões de pesquisa, da elaboração de estratégias de busca e critérios de seleção, da análise dos estudos primários e da categorização dos principais achados.

3.1 Questões de Pesquisa

Com o objetivo de orientar a investigação e sistematizar os estudos encontrados, foram formuladas as seguintes questões de pesquisa:

1. Quais métodos de Inteligência Artificial (IA) são utilizados para prever resultados de partidas de futebol?
2. Quais métricas estatísticas são empregadas para medir o nível de certeza das previsões?
3. Quais bases de dados públicas são utilizadas em trabalhos de predição de resultados?
4. Como os atributos individuais e a escalação inicial são usados para prever resultados de partidas de futebol?
5. Quais são os principais desafios enfrentados por essa abordagem?

3.2 Estratégia de Busca e Seleção

Para a identificação dos estudos primários, foram selecionadas as bases de dados **Google Scholar** e **Web of Science**. A escolha dessas bases se deve à sua ampla cobertura de publicações

acadêmicas nas áreas de *ciência da computação*, *inteligência artificial aplicada ao esporte* e *análise de desempenho no futebol*. As buscas foram realizadas entre os dias **10 de maio de 2015** e **29 de agosto de 2025**. Para o acesso ao conteúdo completo dos artigos, foi utilizado o **Portal de Periódicos da CAPES**, por meio do acesso institucional **CAFe**, disponibilizado pela Universidade Federal de Sergipe.

A utilização do Google Scholar foi especialmente relevante por agregar resultados de diversas bases de dados, proporcionando uma visão abrangente da literatura disponível. Já o Web of Science, por sua curadoria mais restrita, apresentou uma cobertura menor, porém com artigos de maior rigor técnico.

Inicialmente, foram definidas palavras-chave em português e inglês com base nos principais conceitos relacionados ao tema da pesquisa:

- Análise de desempenho / *Performance analysis*
- Futebol / *Football* / *Soccer*
- Predição de resultados / *Match outcome prediction*
- Atributos individuais / *Player attributes*
- Escalação / *Starting lineup* / *Team selection* / *Starting eleven*
- Inteligência Artificial / *Artificial Intelligence*
- Scouting / *Scouting*

Com base nesses termos, foram construídas duas versões da string de busca, sendo a primeira mais abrangente e a segunda mais específica, com o intuito de refinar os resultados e identificar estudos mais relevantes sobre a relação entre **atributos de jogadores**, **escalação inicial** e **predição de resultados**. Os termos em português foram inicialmente considerados, porém não contribuíram de forma significativa para a recuperação de artigos relevantes nas bases analisadas. Dessa forma, optou-se por utilizar exclusivamente os termos em inglês na construção das strings de busca.

String de busca geral

```
("soccer"OR "football") AND "artificial intelligence"AND ("player
attributes"OR "individual performance") AND ("starting lineup"OR
"starting eleven")
```

Essa string inicial resultou em um total de **264 artigos** encontrados no Google Scholar.

String de busca refinada

```
("soccer"OR "football") AND ("artificial intelligence"OR "machine
learning") AND ("player attributes"OR "performance metrics") AND
("starting lineup"OR "team selection") AND ("match prediction"OR
"result prediction")
```

Com essa versão refinada da string, foram encontrados **70 artigos** no Google Scholar e **2 artigos** no Web of Science, demonstrando que a literatura relevante sobre o tema ainda é limitada nas bases de curadoria mais seletiva. A Tabela 1 mostra o resultado da busca utilizando a string refinada.

3.3 Critérios de Seleção

Com o objetivo de filtrar os estudos primários e selecionar os mais relevantes para a análise de predição de resultados em partidas de futebol a partir de atributos individuais dos jogadores, foram definidos critérios rigorosos de inclusão e exclusão. Esses critérios permitiram restringir o escopo da revisão a trabalhos alinhados com os objetivos da pesquisa, garantindo a consistência e a relevância dos estudos analisados.

3.3.1 Critérios de Inclusão

- Artigos que abordam a previsão de resultados de partidas de futebol utilizando atributos individuais dos atletas, como desempenho técnico, físico ou tático.
- Estudos que utilizam técnicas de Inteligência Artificial (IA) — como aprendizado de máquina, redes neurais, árvores de decisão, entre outros — com aplicação prática na análise de partidas de futebol.
- Trabalhos que quantificam a escalação inicial e os jogadores envolvidos, utilizando dados estruturados e abordagens estatísticas ou computacionais para fins de predição.
- Publicações com foco explícito em futebol (*soccer/football*), com dados reais, simulados ou provenientes de bases públicas relevantes.

3.3.2 Critérios de Exclusão

- Artigos que abordam aspectos exclusivamente relacionados a hardware, como sensores físicos, dispositivos vestíveis ou arquiteturas computacionais, sem ligação direta com a predição de resultados baseada em atributos individuais.

- Estudos que fogem do escopo esportivo do futebol, abordando outros esportes ou temáticas muito distintas.
- Trabalhos que tratam da predição de resultados sem considerar atributos individuais dos jogadores ou a escalação inicial, focando apenas em aspectos como histórico de partidas, mandos de campo, clima ou estatísticas agregadas de equipe.
- Textos cujo acesso ao conteúdo completo não foi possível, inviabilizando a análise detalhada e crítica.
- Artigos de caráter incompleto, informal ou sem rigor metodológico, como resumos de trabalhos em andamento, relatórios não revisados por pares ou conteúdos excessivamente descritivos.

Após a aplicação dos critérios de inclusão e exclusão, os estudos primários foram refinados para compor os estudos relevantes. Dos 70 estudos primários inicialmente retornados pela busca, 13 artigos foram selecionados como relevantes para análise.

Tabela 1 – Filtragem dos estudos relevantes

Bases	**Nº Estudos Primários**	**Nº Estudos Relevantes**
Google Scholar	70	12
Web of Science	2	1
Total	**72**	**13**

3.4 Análise dos Resultados

A partir da leitura dos estudos relevantes selecionados, são expostos a seguir os resultados obtidos com base nas questões de pesquisa levantadas na Seção 3.1.

3.4.1 Quais métodos de Inteligência Artificial (IA) são utilizados para prever resultados de partidas de futebol?

A *Inteligência Artificial* (IA), em especial o *Machine Learning* (ML) e o *Deep Learning*, é amplamente utilizada na previsão de resultados de partidas de futebol. Diversos algoritmos e abordagens são aplicados para lidar com a complexidade e a natureza multiclasse dos resultados.

Algoritmos de *Machine Learning* como *Random Forest*, *Gradient Booster*, *Support Vector Machine* (SVM) e regressão logística são comumente empregados, destacando-se por serem mais transparentes que as chamadas "caixas-pretas" das redes neurais (HEIJBOER, 2022). Outros estudos também mencionam redes bayesianas e regressão logística como técnicas relevantes (SJöBERG, 2023).

No âmbito do *Deep Learning*, as *Redes Neurais Artificiais* (RNAs) são predominantes. Entre elas, destacam-se as redes neurais recorrentes (RNR) e convolucionais (RNC) (SJöBERG, 2023). Além disso, redes neurais profundas vêm sendo utilizadas para apoiar decisões estratégicas, como a formação de equipes e a seleção de jogadores com base em características individuais (NOURAIE; ESLAHCHI; BACA, 2023).

Em cenários de previsão do desempenho de jogadores, além dos já citados, são utilizados modelos como *AutoRegressive Integrated Moving Average* (ARIMA), *Multi-layer Perceptron* (MLP) e *Long Short-Term Memory* (LSTM), conforme apontado por (GKIASTAS, 2022). Para a predição de gols esperados (xGg) e gols reais (aGg), também são empregados modelos de regressão como *Regressão Linear*, *Regressão Ridge*, *Regressão Lasso*, *Elastic Net*, *Árvore de Decisão*, *Gradient Boosting* e *AdaBoost*. Dentre esses, destaca-se a *Regressão Ridge*, devido à sua robustez na gestão das características do conjunto de dados e na prevenção de *overfitting* (MALIKOV; KIM, 2024).

3.4.2 Quais métricas estatísticas são empregadas para medir o nível de certeza das previsões?

A avaliação dos modelos preditivos aplicados ao futebol envolve métricas distintas para tarefas de classificação e regressão, conforme discutido na literatura especializada (HEIJBOER, 2022; SJöBERG, 2023; GKIASTAS, 2022).

Nos modelos de *classificação*, que têm como objetivo prever o resultado de uma partida (vitória, empate ou derrota), a literatura aponta o uso recorrente de métricas consolidadas para avaliação do desempenho preditivo. Entre elas, destacam-se a acurácia geral, que expressa a proporção de previsões corretas, bem como as métricas de precisão, *recall* (ou sensibilidade) e F1-score, amplamente empregadas na análise de classificadores. Adicionalmente, a precisão ponderada é utilizada para lidar com o desbalanceamento das classes — em especial a classe de empates — e a matriz de confusão é adotada como ferramenta complementar para a análise detalhada dos acertos e erros por classe.

Essas métricas incluem:

- **Acurácia geral**;
- **Precisão**, **Recall** (sensibilidade) e **F1-score**;
- **Precisão ponderada**;
- **Matriz de confusão**.

Nos modelos de *regressão*, aplicados à previsão de variáveis contínuas — como indicadores de desempenho individual de jogadores —, são empregadas métricas que avaliam o erro

e o ajuste do modelo, conforme descrito em estudos recentes (SJöBERG, 2023; GKIASTAS, 2022). Nesse contexto, destacam-se o coeficiente de determinação (R^2), que mensura o grau de explicação da variabilidade dos dados pelo modelo, o erro médio absoluto (MAE) e a raiz do erro quadrático médio (RMSE), sendo esta última frequentemente utilizada por sua maior interpretabilidade prática.

As principais métricas de regressão consideradas são:

- **Coeficiente de determinação** (R^2);
- **Erro médio absoluto** (MAE);
- **Raiz do erro quadrático médio** (RMSE).

Além dessas métricas, a **validação cruzada** é uma técnica amplamente empregada para aumentar a confiabilidade da avaliação dos modelos (SJöBERG, 2023). Essa abordagem consiste em particionar o conjunto de dados em múltiplos subconjuntos, nos quais o modelo é treinado em uma parte dos dados e avaliado em outra, de forma iterativa. Desse modo, cada observação é utilizada tanto no treinamento quanto na validação ao longo do processo, reduzindo o viés associado a uma única divisão dos dados e proporcionando estimativas mais robustas do desempenho preditivo.

3.4.3 Quais bases de dados públicas são utilizadas em trabalhos de predição de resultados?

A utilização de bases de dados públicas é essencial para o treinamento e validação de modelos preditivos em futebol. As principais bases identificadas nos estudos são:

- **European Soccer Database** (Kaggle), contendo mais de 25 mil jogos de 11 ligas europeias entre 2008 e 2016 (HEIJBOER, 2022; SJöBERG, 2023);
- **Sofifa.com** e **Fifaindex.com**, com dados dos jogos da franquia *FIFA*, incluindo atributos técnicos, físicos e contratuais dos jogadores (SJöBERG, 2023; NOURAIE; ESLAHCHI; BACA, 2023);
- **DataHub.io**, com arquivos CSV organizados e presença do campo `FTR` (Full Time Result) (SJöBERG, 2023);
- **SofaScore**, usado para gerar conjuntos de dados detalhados com mais de 1.500 eventos por partida (GKIASTAS, 2022);
- **TransferMarkt**, utilizado para coletar manualmente informações sobre lesões e suspensões (GKIASTAS, 2022);

- **Classificações da FIFA**, que funcionam como um importante preditor nos modelos, por vezes com maior relevância que a classificação ELO (HEIJBOER, 2022).

3.4.4 Como os atributos individuais e a escalação inicial são usados para prever resultados de partidas de futebol?

Na predição de resultados de partidas de futebol, os atributos dos jogadores e a formação inicial da equipe são variáveis de entrada cruciais. A forma como esses dados são utilizados e sua relação com a previsão de resultados são aspectos fundamentais abordados em estudos recentes.

Os dados utilizados nesses modelos geralmente integram **atributos de jogadores**, **atributos de equipe** e **estatísticas de partidas** (SJöBERG, 2023). A **tabela de atributos do jogador**, disponível em bases como o *European Soccer Database* ou o *sofifa*, apresenta classificações numéricas em habilidades como chute, passe, fisicalidade, ritmo, movimentação, defesa e goleiro (SJöBERG, 2023; NOURAIE; ESLAHCHI; BACA, 2023).

A **escalação inicial** desempenha um papel central nesses modelos, pois os atributos dos 22 jogadores titulares (11 de cada equipe) são considerados em cada partida. A ligação entre a tabela de partidas e os atributos individuais é realizada por meio dos *IDs* dos jogadores, permitindo associar seus perfis estatísticos às partidas em que atuaram (HEIJBOER, 2022).

Os atributos individuais dos atletas incluem não apenas características técnicas, como chute, passe e controle de bola, mas também aspectos físicos como idade, altura, peso e condicionamento, os quais podem ser quantificados por especialistas ou obtidos por sensores e dispositivos de rastreamento (NOURAIE; ESLAHCHI; BACA, 2023; ABIDIN, 2021). Esses atributos compõem vetores de entrada que buscam representar o potencial de desempenho dos jogadores em campo.

Além disso, estudos recentes propõem o uso de *ratings* virtuais para representar a qualidade individual dos atletas e sua contribuição coletiva. Entre essas abordagens, destaca-se o sistema de avaliação de força relativa proposto por Elo (1978). Originalmente concebido para o xadrez, o sistema Elo foi posteriormente adaptado ao contexto do futebol para estimar a probabilidade de vitória a partir da diferença de nível entre equipes.

Conforme discutido por Heijboer (2022), a incorporação de atributos individuais — como os *ratings* FIFA — permite mitigar a lentidão de convergência do sistema Elo tradicional em ligas nacionais, onde o número de partidas por temporada é limitado. Nesse contexto, a média dos *ratings* FIFA da escalação inicial pode ser utilizada como valor inicial do Elo da equipe, influenciando diretamente a previsão do desfecho das partidas.

Outros atributos derivados da escalação inicial incluem:

- Idade média dos titulares;

- Quantidade de jogadores com mais de 30 anos;
- Número de mudanças em relação à última formação;
- Altura e peso médios;
- Frequência de utilização dos jogadores na temporada;

Para muitas dessas variáveis, utilizam-se **diferenças entre equipes** (equipe mandante menos visitante) — como diferença de idade média, de rating FIFA, de altura média — o que melhora a eficiência preditiva dos modelos e reduz a dimensionalidade (HEIJBOER, 2022).

Além disso, métricas como *position weight* e *league weight* têm sido utilizadas para ponderar a relevância dos jogadores com base em suas posições e na qualidade da liga em que atuam, influenciando as variáveis como gols esperados (xG) e gols reais (aG) (MALIKOV; KIM, 2024).

Apesar de boas performances obtidas, desafios permanecem. Modelos tendem a favorecer vitórias do time mais forte ou da equipe mandante, tendo dificuldade em prever empates ou vitórias do time mais fraco (HEIJBOER, 2022).

Assim, conclui-se que os dados individuais e a escalação inicial são, não apenas fundamentais, mas altamente eficazes como preditores no contexto da IA aplicada ao futebol, especialmente quando integrados a técnicas de aprendizado supervisionado e representações agregadas da equipe.

3.4.5 Quais são os principais desafios da predição de resultados de futebol com base em atributos dos jogadores presentes nas escalações iniciais?

Apesar dos avanços na aplicação da Inteligência Artificial à previsão de resultados de futebol, diversos **desafios significativos** ainda limitam a precisão e a abrangência desses modelos:

- **Natureza estocástica do futebol**: O futebol é um esporte intrinsecamente imprevisível. Eventos aleatórios, como um chute desviado ou um gol no último minuto, podem alterar drasticamente o resultado da partida (GKIASTAS, 2022; SJöBERG, 2023). A baixa pontuação típica aumenta a chance de resultados inesperados, dificultando ainda mais a previsão quando comparado a esportes com mais pontos.
- **Fatores não quantificáveis e não registrados**: Modelos computacionais não capturam aspectos subjetivos como condição psicológica, conflitos internos, eventos pessoais ou motivação dos atletas (GKIASTAS, 2022). Esses fatores, embora relevantes, não estão presentes nas bases de dados.

- **Limitações na disponibilidade e atualidade dos dados**: A disponibilidade de dados relevantes pode ser limitada. Alguns estudos utilizam conjuntos de jogadores fixos, desconsiderando histórico de lesões, desempenho e atualizações (GKIASTAS, 2022). Além disso, conjuntos de dados pequenos ou desatualizados impactam negativamente a qualidade das previsões (HEIJBOER, 2022).

- **Dificuldade em classificar empates**: Muitos algoritmos de aprendizado de máquina enfrentam dificuldades em prever empates de maneira eficaz, reduzindo a acurácia dos modelos. Além disso, mesmo algoritmos que identificam corretamente a equipe mais forte muitas vezes falham em prever derrotas inesperadas (HEIJBOER, 2022).

- **Fatores extracampo não considerados**: Fatores como jogos fora da competição nacional, influência de treinadores, e ausência de jogadores importantes geralmente não são incluídos nos modelos, o que limita a robustez das previsões (HEIJBOER, 2022).

- **Impossibilidade de previsão perfeita**: Por fim, Sjöberg (SJöBERG, 2023) argumenta que é impossível prever resultados de futebol com perfeição, mesmo com técnicas avançadas de IA. A imprevisibilidade do esporte é parte de sua essência e charme, e uma previsão perfeita eliminaria esse elemento humano e emocionante do futebol.

3.5 Resultados dos Trabalhos Relacionados

Com base na revisão sistemática conduzida e nos estudos selecionados como relevantes, esta seção apresenta uma análise comparativa dos resultados reportados na literatura que guardam maior proximidade metodológica e conceitual com o presente trabalho. O objetivo é estabelecer uma referência quantitativa entre o desempenho alcançado pelo modelo proposto neste TCC e os valores tipicamente reportados no estado da arte.

De modo geral, a literatura aponta que a acurácia média de modelos voltados à predição de resultados de partidas de futebol situa-se, predominantemente, entre **55% e 70%**, dependendo da base de dados, do recorte temporal, da representação das variáveis e do algoritmo utilizado (HEIJBOER, 2022; SJöBERG, 2023). No contexto deste trabalho, o melhor desempenho foi obtido pela arquitetura de *Redes Neurais Multilayer Perceptron* (MLP), que atingiu uma **acurácia de 69,36%** e um **F1-Score de 80,61%**, utilizando atributos individuais agregados dos jogadores presentes na escalação inicial.

Entre os estudos citados nesta revisão, destacam-se aqueles que apresentam resultados e abordagens mais comparáveis ao cenário investigado neste TCC:

- **Sjöberg (2023):** O autor avaliou múltiplos algoritmos aplicados à liga alemã (*Bundesliga*), utilizando atributos de equipe e dados derivados do simulador FIFA. O melhor desempenho

reportado foi obtido com *Regressão Logística*, alcançando uma **acurácia de 63,0%**. O estudo destaca limitações na predição de empates, uma dificuldade recorrente na literatura.

- **Shin e Gasparyan (2014):** Este trabalho, citado por validar o uso de atributos virtuais, utilizou *Linear SVM* para prever partidas da *La Liga* espanhola. Os autores reportaram uma acurácia de **73%** utilizando dados reais e de **79%** utilizando dados virtuais da franquia FIFA. Ressalta-se que esses resultados foram obtidos em um cenário específico, com bases de dados e recortes distintos do presente estudo.

- **Heijboer (2022):** Aplicando modelos como *Random Forest* e *SVM* sobre a *European Soccer Database*, o autor reporta desempenhos situados dentro do intervalo médio da literatura, entre **55% e 70%**, destacando desafios relacionados ao desbalanceamento das classes e à predição de empates.

Tabela 2 – Comparação de desempenho entre melhor modelo deste trabalho e a literatura citada

Trabalho	**Modelo**	**Base de Dados**	**Acurácia**	**F1-Score**
Este Trabalho (2026)	MLP	Dataset Consolidado (Barcelona)	69,36%	80,61%
Shin e Gasparyan (2014)	Linear SVM	FIFA / La Liga	73,00%*	–
Sjöberg (2023)	Regressão Logística	Bundesliga / FIFA	63,00%	–
Heijboer (2022)	RF / SVM	European Soccer Database	55–70%	–

*Resultado obtido em cenário específico com dados reais; o valor reportado para dados virtuais foi de 79%.

3.5.1 Síntese Comparativa

Os resultados obtidos neste trabalho posicionam-se no **limite superior do intervalo predominante reportado na literatura**, conforme discutido por Heijboer (HEIJBOER, 2022) e observado nos estudos de Sjöberg (SJöBERG, 2023). A proximidade entre os valores alcançados neste TCC e os resultados reportados por Shin e Gasparyan (SHIN; GASPARYAN, 2014) reforça a viabilidade do uso de **atributos individuais e *ratings* virtuais** como preditores robustos do desempenho esportivo.

Diferentemente de abordagens que dependem exclusivamente de estatísticas dinâmicas de jogo, os resultados deste trabalho indicam que a modelagem das interações não lineares entre habilidades técnicas individuais — capturadas por meio de redes neurais — permite atingir níveis de desempenho compatíveis com os principais benchmarks acadêmicos, mesmo em cenários com restrição de dados e foco em um único clube.

4

Construção da Base de Dados

A construção de um *dataset* robusto e representativo constitui etapa fundamental para análises preditivas no contexto esportivo. Este capítulo descreve o processo de integração de múltiplas bases de dados heterogêneas, tratamento de inconsistências e estruturação final do conjunto de dados utilizado neste trabalho.

4.1 Bases de Dados Originais

O conjunto de dados utilizado neste trabalho foi construído a partir da integração de três bases distintas, complementares e publicamente disponíveis: o *European Soccer Database*, o *Ultimate Soccer Dataset* (Baselight) e o *FIFA Official Dataset* (FIFA17–FIFA23). A adoção dessa estratégia teve como objetivo combinar a riqueza estrutural e histórica das bases clássicas de futebol com dados mais recentes e detalhados sobre partidas, além de avaliações individuais atualizadas dos jogadores.

4.2 European Soccer Database

O *European Soccer Database* é uma base de dados relacional amplamente empregada em pesquisas acadêmicas e aplicações de aprendizado de máquina no contexto do futebol. Seu principal diferencial é a estrutura altamente normalizada, organizada em múltiplas tabelas inter-relacionadas que representam entidades fundamentais do esporte. A base está publicamente disponível na plataforma Kaggle[1].

- **Período de Cobertura:** 2008 a 2016
- **Cobertura Geográfica:** Ligas europeias de primeira e segunda divisões

[1] <https://www.kaggle.com/datasets/groleo/european-football-database>

Tabela 3 – Estrutura e volumetria do European Soccer Database

Tabela	Registros	Colunas	Descrição
`Player`	~11.000	7	Informações básicas dos jogadores
`Player_Attributes`	~183.000	42	Atributos técnicos temporais
`Team`	~300	5	Identificação das equipes
`Team_Attributes`	~1.500	25	Características táticas das equipes
`Match`	~25.000	115	Partidas oficiais registradas
`League`	11	3	Ligas europeias
`Country`	11	2	Países participantes

Principais Limitações:

- Ausência de dados pós-2016;
- Cobertura restrita a ligas europeias;
- Granularidade limitada de eventos de partida.

4.3 Ultimate Soccer Dataset (Baselight)

O *Ultimate Soccer Dataset* foi incorporado para expandir significativamente a cobertura temporal, geográfica e a granularidade dos dados. A base está publicamente disponível na plataforma Baselight[2].

- **Período de Cobertura:** 2008 a dezembro de 2026
- **Cobertura Geográfica:** Competições globais

Tabela 4 – Estrutura e volumetria do Ultimate Soccer Dataset

Tabela	Registros	Colunas	Descrição
`Matches`	>150.000	30+	Partidas globais
`Lineups`	>300.000	15+	Escalações e substituições
`Players`	>100.000	10+	Cadastro de jogadores
`Player_Stats`	Milhões	20+	Estatísticas individuais por jogo
`Teams`	>5.000	8+	Equipes globais
`Transfers`	>50.000	10+	Transferências registradas

Contribuições Principais:

- Extensão temporal até 2026;

[2] <https://baselight.app/u/blt/dataset/ultimate_soccer_dataset>

- Inclusão de competições internacionais;
- Estatísticas individuais detalhadas por partida;
- Dados de escalações completas (titulares e suplentes).

4.4 FIFA Official Dataset (FIFA17–FIFA23)

O *FIFA Official Dataset* consiste em um banco de dados tabular extraído das versões oficiais do jogo eletrônico FIFA, abrangendo múltiplas edições anuais. Apesar de sua origem em um simulador virtual, o uso desses atributos é justificado por sua capacidade de atuar como uma *proxy* padronizada e consistente da qualidade técnica de jogadores profissionais. Estudos comparativos demonstram que modelos preditivos treinados com dados virtuais podem alcançar desempenho competitivo — e, em alguns casos, superior — em relação a modelos baseados exclusivamente em estatísticas reais agregadas, especialmente em cenários com dados escassos ou altamente ruidosos (SHIN; GASPARYAN, 2014). A base está publicamente disponível na plataforma Baselight (espelhada do Kaggle)[3].

Além disso, os *ratings* provenientes do FIFA desempenham papel relevante na inicialização de métricas de força relativa de equipes, como o sistema Elo (1978). Conforme discutido por Heijboer (2022), a incorporação de atributos individuais permite uma convergência mais rápida do nível estimado das equipes, mitigando limitações do uso isolado de resultados históricos. Estratégias semelhantes são exploradas por Matano, Rossi e Pappalardo (2018), que evidenciam ganhos de desempenho ao integrar conhecimento prévio e atributos sintéticos em modelos de aprendizado de máquina aplicados ao esporte.

- **Estrutura:** Snapshots anuais desnormalizados
- **Período de Cobertura:** 2016 a 2023

Tabela 5 – Estrutura e volumetria do FIFA Official Dataset

Versão	Registros	Colunas	Observações
FIFA17-FIFA22	~13.000-17.000	65	Atributos técnicos detalhados
FIFA23	17.660	29	Estrutura simplificada

Categorias de Variáveis:

- **Avaliações globais:** `overall`, `potential`, `special`;
- **Atributos técnicos:** Finalização, passe, drible, controle de bola (FIFA17-FIFA22);

[3] <https://baselight.app/u/kaggle/dataset/bryanb_fifa_player_stats_database/table-explorer>

- **Atributos físicos:** Velocidade, aceleração, resistência, força;
- **Atributos defensivos:** Marcação, desarme, interceptação;
- **Atributos de goleiro:** Reflexos, posicionamento, defesa de pênalti;
- **Informações contratuais:** Clube, valor de mercado, salário.

Limitação Importante: A partir do FIFA23, os atributos técnicos granulares foram removidos, mantendo apenas variáveis agregadas.

4.5 Preparação de Dados

A integração das três bases foi realizada através de um pipeline ETL (*Extract, Transform, Load*) estruturado, garantindo consistência e integridade dos dados. Por isso, o alinhamento foi realizado por meio de chaves comuns:

- **Partidas:** Identificação por data, equipes mandante/visitante e competição. Resolução de conflitos por correspondência *fuzzy* de nomes de equipes.
- **Jogadores:** Correspondência por nome completo e data de nascimento. Tratamento de inconsistências ortográficas (ex: acentuação, abreviações) e validação por clube e temporada.
- **Equipes:** Padronização de nomenclatura (ex: "FC Barcelona"vs "Barcelona FC") e criação de tabela de sinônimos para resolução automática.
- **Temporadas:** Padronização no formato YYYY (ano inicial da temporada) e tratamento de diferenças entre calendários (europeu vs sul-americano).

4.5.1 Tratamento de Redundâncias

Durante a integração, foram identificadas e tratadas redundâncias:

Código 1 – Remoção de duplicatas por chave composta

```
df_integrated = df_integrated.drop_duplicates(
    subset=['data', 'home_team', 'away_team', 'competition'],
    keep='first'
)
```

4.5.2 Resolução de Conflitos

Quando múltiplas bases continham informações divergentes para a mesma partida:

1. **Prioridade por recência:** Dados do *Ultimate Soccer Dataset* prevaleceram sobre o *European Soccer Database*.
2. **Validação cruzada:** Resultados de partidas foram validados em ambas as bases.
3. **Features complementares:** Atributos únicos de cada base foram preservados.

4.6 Construção do Dataset Específico do FC Barcelona

Após a integração das bases originais, foi construído um *dataset* focado exclusivamente nas partidas do FC Barcelona.

4.6.1 Seleção e Filtragem de Partidas

Critérios de Seleção:

- Time identificado como "FC Barcelona"ou "BAR";
- Partidas oficiais (excluindo amistosos);
- Período: 2009 a 2026;
- Escalações completas disponíveis (11 jogadores titulares).

Código 2 – Identificação das partidas do FC Barcelona

```
barcelona_matches = df_all_matches[
    (df_all_matches['home_team'] == 'FC Barcelona') |
    (df_all_matches['away_team'] == 'FC Barcelona')
].copy()

print(f"Total de partidas identificadas: {len(barcelona_matches)}")
```

Resultado: 864 partidas selecionadas.

4.6.2 Definição da Variável Alvo

A variável dependente (*target*) foi definida como binária:

- **Vitória (1):** Barcelona venceu a partida;

- **Não Vitória (0):** Barcelona empatou ou perdeu.

Código 3 – Definição da variável alvo binária (vitória/não vitória)

```
def definir_target(row):
    if row['home_team'] == 'FC Barcelona':
        return 1 if row['home_goals'] > row['away_goals'] else 0
    else:
        return 1 if row['away_goals'] > row['home_goals'] else 0

df_features['target'] = df_features.apply(definir_target, axis=1)
```

Distribuição Resultante:

- Vitórias: 602 partidas (69,7%)
- Não Vitórias: 262 partidas (30,3%)

Esta distribuição reflete a dominância histórica do Barcelona no período analisado.

4.6.3 Padronização da Variável Mando de Campo

A variável `mando_time` foi padronizada numericamente:

Código 4 – Padronização da variável de mando de campo

```
if df_features['mando_time'].dtype == 'object':
    df_features['mando_time'] = df_features['mando_time'].map({
        'home': 1,
        'away': 0
    })
    df_features['mando_time'] =
       df_features['mando_time'].fillna(1).astype(int)
```

Distribuição:

- Mandante (casa): ~50%
- Visitante (fora): ~50%

4.6.4 Integração de Atributos dos Jogadores

Para cada uma das 11 posições em campo, foram extraídos e associados os atributos individuais dos jogadores titulares do FIFA Dataset correspondente à temporada da partida.

Processo de Correspondência Temporal:

Código 5 – Função de correspondência temporal entre temporada e versão FIFA

```
def obter_atributos_fifa(jogador_nome, temporada):
    ano_fifa = temporada if temporada >= 2017 else 2017

    if ano_fifa > 2023:
        ano_fifa = 2023

    df_fifa = carregar_fifa_versao(ano_fifa)
    jogador_data = df_fifa[df_fifa['short_name'] == jogador_nome]

    if len(jogador_data) == 0:
        jogador_data = busca_fuzzy(df_fifa, jogador_nome)

    return jogador_data.iloc[0] if len(jogador_data) > 0 else None
```

Atributos Extraídos por Jogador:

Tabela 6 – Categorias de atributos por jogador

Categoria	Qtd	Exemplos
Ofensivos	8-12	`finishing`, `crossing`, `dribbling`
Defensivos	4-6	`marking`, `tackle`, `interceptions`
Físicos	5-7	`sprint_speed`, `stamina`, `strength`
Técnicos	6-8	`ball_control`, `passing`, `vision`
Goleiro	5	`gk_diving`, `gk_reflexes`, `gk_positioning`
Gerais	2-3	`overall`, `potential`

Nomenclatura das Colunas: Para cada jogador $i \in [1, 11]$ e atributo *attr*:

- Identificação: `player_i_name`, `player_i_position`
- Atributos: `player_i_attr` (ex: `player_3_crossing`)

Resultado: Cada partida passou a conter ~275 *features* numéricas de atributos dos jogadores, além das variáveis contextuais.

4.6.5 Tratamento de Dados Ausentes

Estratégias Aplicadas:

Código 6 – Imputação de valores ausentes pela mediana

```
X = X.fillna(X.median())
```

Escalações Incompletas:

- Partidas com menos de 11 jogadores identificados foram excluídas.
- Critério: Mínimo de 9 jogadores com atributos completos.

Correspondência FIFA:

- Jogadores não encontrados no FIFA: Busca por nome similar (Levenshtein distance < 2).
- Fallback: Uso de médias por posição quando jogador não identificado.

4.6.6 Validação e Consistência

Verificações Implementadas:

Código 7 – Verificação de integridade e consistência do dataset

```
print(f"Total de partidas: {len(df_features)}")
print(f"Partidas com escala es completas: {(df_features['player_11_name'].notna()).sum()}")
print(f"Features num ricas: {len([col for col in df_features.columns if df_features[col].dtype in ['float64', 'int64']])}")
print(f"Valores ausentes por coluna: {df_features.isnull().sum().sum()}")

print(f"Per odo: {df_features['data'].min()} at {df_features['data'].max()}")
print(f"Temporadas: {sorted(df_features['temporada'].unique())}")
```

Estatísticas Finais:

- **Total de partidas:** 864
- **Features por partida:** ~275 numéricas + 22 categóricas (nomes e posições)
- **Período:** 2009 a 2026 (17 temporadas)
- **Completude:** 100% das partidas com 11 jogadores identificados

4.7 Estrutura Final do Dataset

O *dataset* final (`barcelona_dataset.csv`) apresenta a seguinte estrutura consolidada:

Tabela 7 – Estrutura consolidada do dataset final

Categoria	**Colunas**	**Descrição**
Temporais	2	`data`, `temporada`
Contextuais	2	`mando_time`, `adversario`
Alvo	1	`target` (vitória/não vitória)
Jogadores (ID)	22	`player_i_name`, `player_i_position`
Atributos Jogadores	275+	`player_i_attribute`
Total	**~300**	-
Partidas		**864**

- **Formato de Armazenamento:** CSV (Comma-Separated Values)
- **Tamanho:** ~15 MB
- **Encoding:** UTF-8

4.8 Análise Exploratória Preliminar

Antes de prosseguir para a modelagem, foi conduzida análise exploratória inicial para caracterizar o *dataset*:

4.8.1 Distribuição da Variável Alvo

Código 8 – Distribuição da variável alvo

```
vitorias = (df_features['target'] == 1).sum()
nao_vitorias = (df_features['target'] == 0).sum()

print(f"Vit rias: {vitorias}
    ({vitorias/len(df_features)*100:.1f}%)")
print(f"N  o  Vit rias: {nao_vitorias}
    ({nao_vitorias/len(df_features)*100:.1f}%)")
```

Resultado: Desbalanceamento natural com 69,7% de vitórias.

4.8.2 Distribuição por Mando de Campo

Código 9 – Distribuição das partidas por mando de campo

```
mandante_count = (df_features['mando_time'] == 1).sum()
visitante_count = (df_features['mando_time'] == 0).sum()

print(f"Mandante: {mandante_count}
    ({mandante_count/len(df_features)*100:.1f}%)")
print(f"Visitante: {visitante_count}
    ({visitante_count/len(df_features)*100:.1f}%)")
```

4.9 Considerações Finais do Capítulo

Este capítulo apresentou de forma detalhada o processo de construção do conjunto de dados utilizado neste trabalho, desde a seleção e integração de múltiplas bases públicas heterogêneas até a estruturação final do *dataset* específico para as partidas do FC Barcelona. Foram descritas as etapas de limpeza, padronização, resolução de conflitos, tratamento de dados ausentes e validação de consistência, garantindo a integridade e a qualidade das informações utilizadas nas análises subsequentes.

A integração do *European Soccer Database*, do *Ultimate Soccer Dataset* e do *FIFA Official Dataset* permitiu combinar dados históricos de partidas, informações detalhadas de escalações e atributos individuais dos jogadores, resultando em um conjunto de dados rico, coerente e adequado ao objetivo de predição de resultados com base na escalação inicial. Como resultado, obteve-se um *dataset* consolidado com 864 partidas e aproximadamente 300 variáveis, das quais cerca de 275 correspondem a atributos numéricos dos jogadores.

Destaca-se que a opção por focar em um único clube, o FC Barcelona, permitiu maior controle sobre a consistência temporal e a qualidade das informações, ao custo de reduzir a generalização imediata dos resultados para outros contextos. Da mesma forma, o uso de atributos provenientes da franquia FIFA, embora amplamente validado na literatura como *proxy* da qualidade técnica dos jogadores, constitui uma aproximação indireta do desempenho real em campo, devendo ser interpretado dentro dessas limitações.

Ainda assim, o conjunto de dados obtido apresenta-se como uma base sólida e apropriada para a etapa de modelagem preditiva, descrita no próximo capítulo. A partir dessa estrutura, torna-se possível investigar de forma sistemática o impacto dos atributos individuais e da escalação inicial no desempenho dos modelos de aprendizado de máquina e, consequentemente, na predição de resultados de partidas de futebol.

5

Pipeline De Modelagem Preditiva

Este capítulo apresenta o pipeline de modelagem preditiva adotado neste trabalho, desde o pré-processamento dos dados até os procedimentos de avaliação dos modelos. O foco principal é a descrição das decisões metodológicas e do protocolo experimental, enquanto detalhes extensos de implementação foram deslocados para os apêndices, de modo a preservar a clareza do texto e a reprodutibilidade dos experimentos.

O pipeline foi estruturado segundo boas práticas de aprendizado de máquina, garantindo: (i) separação adequada entre treino, validação e teste; (ii) padronização no processo de avaliação; e (iii) comparabilidade justa entre algoritmos distintos.

5.1 Pré-processamento de Dados

O dataset utilizado contém atributos numéricos de jogadores, bem como colunas de identificação textual (nomes, posições e datas) e valores ausentes. Para tornar os dados adequados à modelagem supervisionada, foi aplicado um processo de pré-processamento composto por três etapas: seleção de features numéricas, imputação de valores ausentes e normalização.

Inicialmente, foram removidas colunas de identificação e atributos categóricos em formato textual, evitando a introdução de ruído e viés nos modelos. Em seguida, os valores ausentes foram tratados por imputação da mediana, estratégia robusta frente a distribuições assimétricas e valores extremos, características frequentes em dados de desempenho esportivo. Por fim, aplicou-se a padronização Z-score, assegurando média zero e desvio padrão unitário para todas as variáveis, o que é especialmente relevante para algoritmos sensíveis à escala.

O trecho essencial do pré-processamento é apresentado no Código 10.

Código 10 – Pré-processamento essencial das features

```
cols_drop = ['target', 'temporada', 'data', 'target_label']
cols_drop += [c for c in df_features.columns if '_name' in c or
    '_position' in c]

X = df_features.drop(cols_drop, axis=1, errors='ignore')
y = df_features['target']

X = X.select_dtypes(include=[np.number])
X = X.fillna(X.median())

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Conforme ilustrado no Código 10, esse procedimento resulta em um conjunto de atributos exclusivamente numéricos, normalizados e consistentes, adequado para o treinamento dos modelos preditivos.

5.2 Divisão Estratificada dos Dados

Para avaliar corretamente a capacidade de generalização dos modelos, o dataset foi dividido em três subconjuntos: treino (60%), validação (20%) e teste (20%). A divisão foi realizada de forma estratificada, preservando a proporção entre as classes de vitória e não vitória em todas as partições.

A separação do conjunto de validação permite acompanhar o desempenho dos modelos durante o desenvolvimento, reduzindo o risco de ajuste excessivo ao conjunto de teste.

A divisão estratificada em conjuntos de treino, validação e teste é realizada conforme mostrado no Código 11.

Código 11 – Divisão estratificada em treino, validação e teste

```
X_temp, X_test, y_temp, y_test = train_test_split(
    X_scaled, y, test_size=0.20, random_state=RANDOM_STATE,
        stratify=y
)

X_train, X_val, y_train, y_val = train_test_split(
    X_temp, y_temp, test_size=0.25, random_state=RANDOM_STATE,
        stratify=y_temp
)
```

5.3 Treinamento dos Modelos

Foram avaliados **Foram avaliados oito algoritmos de aprendizado supervisionado**, , abrangendo modelos lineares, técnicas de ensemble, métodos de boosting e redes neurais artificiais. Para garantir comparabilidade justa, todos os modelos foram treinados sob o mesmo protocolo experimental, utilizando o mesmo conjunto de treino e as mesmas features normalizadas.

Considerando o desbalanceamento natural entre as classes, foi adotado tratamento de pesos balanceados sempre que disponível, de modo a reduzir a tendência dos modelos em favorecer a classe majoritária. Os hiperparâmetros foram definidos com base em recomendações da literatura e experimentação preliminar.

Como os trechos de treinamento diferem majoritariamente apenas na definição do estimador e de seus hiperparâmetros, apresenta-se no Código 12 um modelo representativo: o MLP, que obteve o melhor desempenho geral. A implementação completa dos demais modelos encontra-se no Apêndice A.

Código 12 – Treinamento do modelo MLP

```
mlp = MLPClassifier(
    hidden_layer_sizes=(128, 64, 32),
    activation='relu',
    solver='adam',
    max_iter=500,
    random_state=RANDOM_STATE,
    early_stopping=True,
    validation_fraction=0.1
)
mlp.fit(X_train, y_train)
```

Conforme definido no Código 12, a arquitetura adotada busca equilibrar capacidade de modelagem não linear e controle de complexidade, enquanto o mecanismo de *early stopping* contribui para a prevenção de sobreajuste.

5.4 Avaliação Padronizada

A avaliação dos modelos foi conduzida por meio de um procedimento padronizado, garantindo que todas as métricas fossem calculadas de forma consistente. Foram utilizadas as métricas de acurácia, precisão, recall e F1-Score, além da matriz de confusão, que permite uma análise mais detalhada dos erros de classificação.

A padronização da avaliação reduz vieses de implementação e fortalece a validade das comparações entre os diferentes algoritmos.

A função unificada de avaliação utilizada neste trabalho é apresentada no Código 13.

Código 13 – Função unificada de avaliação

```
def avaliar(modelo, X, y):
    y_pred = modelo.predict(X)
    return {
        'accuracy': accuracy_score(y, y_pred),
        'precision': precision_score(y, y_pred, zero_division=0),
        'recall': recall_score(y, y_pred, zero_division=0),
        'f1': f1_score(y, y_pred, zero_division=0),
        'cm': confusion_matrix(y, y_pred)
    }

res_teste = avaliar(mlp, X_test, y_test)
```

Por meio da função definida no Código 13, todas as métricas são calculadas de forma padronizada, garantindo consistência na comparação entre os modelos.

Os resultados comparativos entre os modelos, bem como as matrizes de confusão, são discutidos em detalhe no Capítulo 6.

5.5 Experimentos de Representação de Features

Além da comparação entre algoritmos, foram conduzidos experimentos para avaliar o impacto de diferentes representações de atributos no desempenho preditivo. Foram analisadas quatro abordagens: atributos agregados, uso de todos os atributos, médias por jogador e subconjunto de atributos-chave.

O objetivo desses experimentos é verificar se estratégias de agregação reduzem ruído e melhoram a generalização dos modelos, em comparação com representações de alta dimensionalidade. Os detalhes completos de implementação desses experimentos encontram-se no Apêndice B, enquanto os resultados são apresentados no Capítulo 6.

5.6 Análise Temporal Incremental

Para aproximar o cenário experimental de uma aplicação real, foi realizada uma análise temporal incremental por meio da validação *walk-forward*. Essa abordagem é particularmente adequada no contexto de predição esportiva, pois, conforme discutido por Sjöberg (2023), procedimentos tradicionais de validação cruzada não são apropriados quando a ordem cronológica dos dados deve ser preservada. Em problemas desse tipo, o uso indevido de informações futuras pode introduzir viés e comprometer a validade dos resultados.

Nesse procedimento, os modelos são treinados exclusivamente com dados de temporadas passadas e avaliados na temporada seguinte, garantindo que o modelo nunca utilize informações

do futuro para prever eventos do passado, o que evita o vazamento temporal (*data leakage*). Essa metodologia está alinhada aos princípios de avaliação sistemática descritos no framework proposto por Bunker e Thabtah (2019).

A implementação completa da validação temporal incremental utilizada neste trabalho encontra-se apresentada no Apêndice C. A análise detalhada dos resultados obtidos por meio desse procedimento é discutida no Capítulo 6.

5.7 Análise de Importância de Atributos

Por fim, foi conduzida uma análise de importância de atributos com o modelo ***Random Forest***, permitindo interpretar quais características exercem maior influência nas previsões. Adicionalmente, as importâncias foram agregadas por jogador, fornecendo uma visão mais alinhada ao domínio do futebol.

A implementação detalhada dessa análise encontra-se no Apêndice D, enquanto as conclusões derivadas são discutidas no Capítulo 6.

6

Resultados e Discussões

6.1 Preparação e Análise Descritiva dos Dados

O dataset final utilizado neste estudo compreendeu **864 partidas** do FC Barcelona, abrangendo múltiplas temporadas e competições. A análise exploratória inicial revelou características importantes sobre a distribuição dos dados e o contexto das partidas analisadas.

Distribuição de Resultados: A variável alvo apresentou uma distribuição natural característica do desempenho histórico do clube, com **602 vitórias (69,7%)** e **262 não vitórias (30,3%)**. Esta distribuição reflete a dominância histórica do Barcelona no futebol europeu.

Divisão do Conjunto de Dados: Seguindo as melhores práticas de validação em aprendizado de máquina, os dados foram estratificados e divididos em três conjuntos distintos:

- **Conjunto de Treino:** 518 partidas (60%)
- **Conjunto de Validação:** 173 partidas (20%)
- **Conjunto de Teste:** 173 partidas (20%)

A divisão estratificada garantiu que a proporção de vitórias e não vitórias fosse mantida em todos os subconjuntos, preservando a representatividade estatística dos dados.

Características das Features: O dataset consolidou **275 features numéricas**, incluindo atributos individuais dos 11 jogadores titulares extraídos do banco de dados FIFA, métricas agregadas de equipe, e variáveis contextuais como mando de campo e temporada.

6.1.1 Desempenho Comparativo dos Modelos

Foram avaliados **oito algoritmos de aprendizado de máquina** na, abrangendo desde métodos clássicos até técnicas de ensemble avançadas. A Tabela 8 apresenta o desempenho

comparativo no conjunto de teste.

Tabela 8 – Desempenho dos modelos no conjunto de teste

Modelo	Acurácia	Precisão	Recall	F1-Score
MLP (Rede Neural)	**69,36%**	**71,43%**	**92,45%**	**80,61%**
Random Forest	67,63%	69,77%	90,57%	78,87%
CatBoost	63,58%	66,67%	86,79%	75,47%
XGBoost	62,43%	65,45%	86,79%	74,70%
LightGBM	61,85%	64,94%	86,79%	74,42%
Gradient Boosting	61,27%	64,47%	86,79%	74,07%
SVM	61,27%	64,47%	86,79%	74,07%
Regressão Logística	60,69%	64,00%	86,79%	73,71%

Melhor Modelo: A arquitetura de **Redes Neurais Artificiais (MLP)** com três camadas ocultas (128, 64 e 32 neurônios) demonstrou desempenho superior, alcançando **69,36% de acurácia** no conjunto de teste. Este resultado sugere que a natureza não-linear e complexa das interações entre os atributos dos jogadores é melhor capturada por arquiteturas de deep learning.

Análise por Métrica:

- **Recall Elevado:** Todos os modelos apresentaram recall superior a 86%, indicando alta capacidade de identificar vitórias corretamente.
- **Precisão Moderada:** A precisão variou entre 64% e 71%, refletindo o desafio de minimizar falsos positivos (classificar não vitórias como vitórias).
- **F1-Score:** O MLP obteve o melhor equilíbrio entre precisão e recall, com F1-Score de 80,61%.

Modelos de Ensemble: Random Forest apresentou o segundo melhor desempenho (67,63%), demonstrando robustez em lidar com a alta dimensionalidade dos dados. Os algoritmos baseados em gradient boosting (XGBoost, LightGBM, CatBoost) apresentaram desempenho intermediário, convergindo em torno de 62-64% de acurácia.

Modelos Tradicionais: SVM e Regressão Logística, embora computacionalmente mais eficientes, apresentaram limitações em capturar padrões complexos, obtendo as menores acurácias do estudo (aproximadamente 61%).

6.1.2 Experimentos de Representação de *Features*

Para investigar o impacto da engenharia de *features* na predição, foram conduzidos quatro experimentos sistemáticos, descritos na Tabela 9, com diferentes estratégias de agregação dos atributos dos jogadores. Os resultados visuais comparativos podem ser observados na Figura 9.

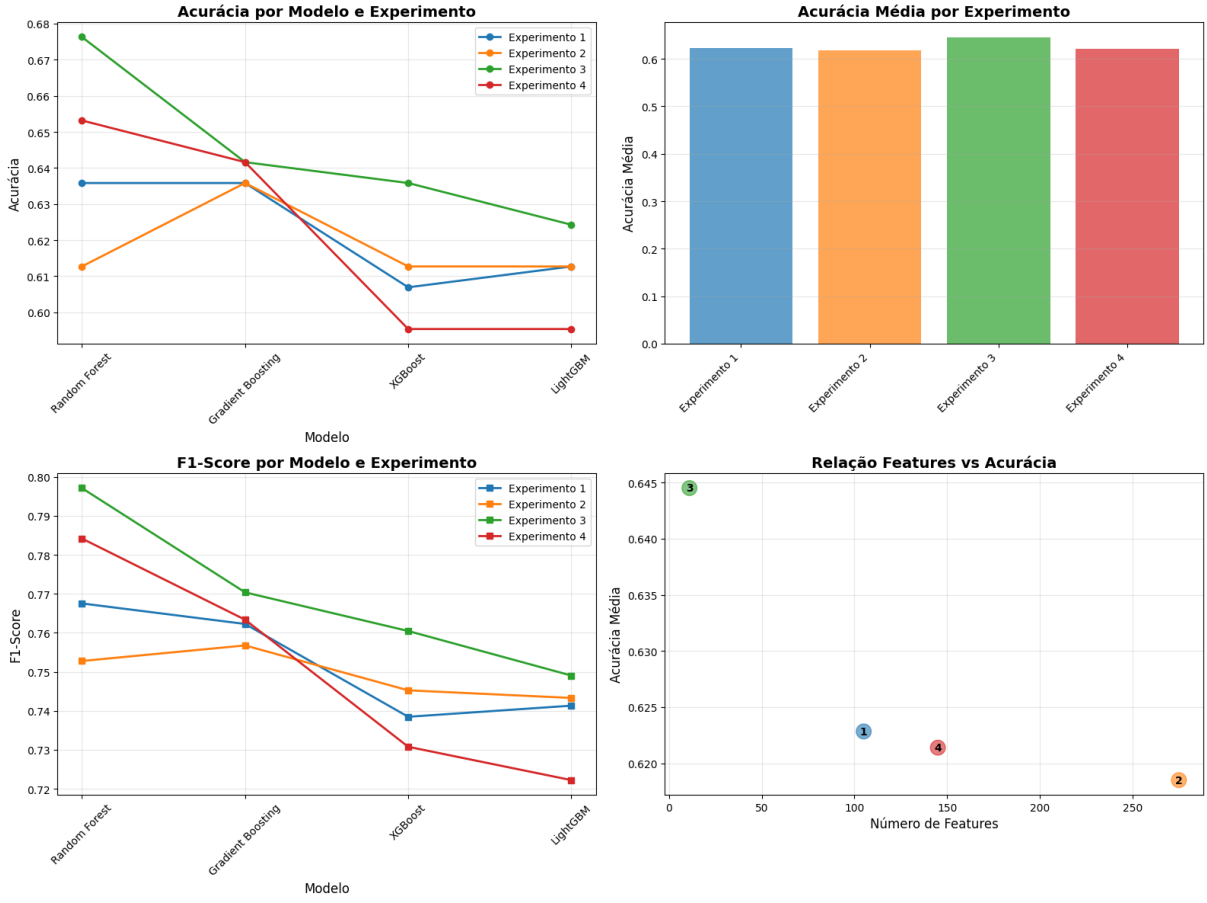

Figura 9 – Análise comparativa: Acurácia e F1-Score por modelo e experimento, e relação entre número de features e desempenho.

Tabela 9 – Comparação entre experimentos de representação de features

Experimento	Descrição	Nº Features	Acurácia Média	F1-Score Médio
Experimento 3	**Médias por Jogador**	**11**	**64,45%**	**75,23%**
Experimento 1	Atributos Agregados	110	63,10%	74,15%
Experimento 4	Atributos-Chave	209	62,35%	73,58%
Experimento 2	Todos Atributos	275	61,85%	73,42%

Experimento 3 - Médias por Jogador (Melhor Resultado): Esta abordagem, que calcula a média de todos os atributos FIFA para cada um dos 11 jogadores, resultando em apenas 11 *features*, obteve a **melhor acurácia média (64,45%)** e o maior F1-Score médio entre os experimentos. Esse resultado é particularmente significativo, pois indica que uma representação compacta e semanticamente agregada consegue preservar a informação essencial da escalação, ao mesmo tempo em que reduz ruído e redundância presentes nos atributos individuais.

Experimento 2 - Todos Atributos Individuais (Baseline): O uso de todas as 275 *features* numéricas disponíveis resultou na menor acurácia média (61,85%). Esse comportamento

sugere que o aumento da dimensionalidade, sem uma estratégia de agregação ou seleção mais estruturada, pode prejudicar a capacidade de generalização dos modelos, favorecendo efeitos como a *curse of dimensionality* e maior propensão ao *overfitting*.

Experimento 1 - Atributos Agregados: Com 110 *features* selecionadas por posição e função, obteve 63,10% de acurácia média, desempenho intermediário. Esse resultado indica que a agregação parcial já é benéfica em relação ao uso de atributos totalmente brutos, mas ainda não atinge o nível de simplificação e robustez observado no Experimento 3.

Experimento 4 - Atributos-Chave: Focando em 209 *features* consideradas mais relevantes para o futebol (finalização, passe, defesa), alcançou 62,35% de acurácia média, apresentando desempenho intermediário entre as demais abordagens. Isso mostra que a simples seleção de variáveis, sem uma agregação estrutural mais forte, não é suficiente para maximizar o desempenho preditivo.

Conclusão dos Experimentos: Os resultados apresentados na Tabela 9 e na Figura 9 evidenciam que existe um compromisso entre complexidade do modelo e capacidade de generalização. O achado mais relevante é que **representações mais simples e bem agregadas de *features* superam conjuntos maiores de atributos brutos**, reforçando o princípio de parcimônia na modelagem preditiva e indicando que a forma de representar a escalação inicial é tão importante quanto o algoritmo utilizado.

6.1.3 Análise Visual e Matrizes de Confusão

As matrizes de confusão fornecem insights detalhados sobre os padrões de erro dos modelos treinados. A Figura 10 apresenta a matriz de confusão do modelo MLP, que obteve o melhor desempenho geral, enquanto a Figura 11 mostra o comportamento do modelo ***Random Forest*** para fins de comparação.

Figura 10 – Matriz de Confusão - MLP (Melhor Modelo)

		Predito	
		Não Vitória	Vitória
Real	Não Vit.	16	36
	Vitória	17	104

Análise do MLP: Conforme evidenciado na Figura 10, o modelo apresenta os seguintes resultados:

- **True Positives (Vitórias):** 104 partidas corretamente classificadas como vitória (86,0% de recall para a classe positiva)
- **False Positives:** 36 não vitórias classificadas erroneamente como vitória (taxa de erro tipo I)

- **True Negatives:** 16 não vitórias corretamente identificadas (30,8% de especificidade)
- **False Negatives:** 17 vitórias classificadas como não vitória (taxa de erro tipo II)

Comportamento Observado: Como pode ser observado na Figura 10, o modelo apresenta alta sensibilidade para vitórias, mas dificuldade em identificar corretamente partidas de não vitória. Esse padrão reflete a tendência do classificador em favorecer a classe majoritária, coerente com a distribuição histórica dos resultados do clube analisado.

Figura 11 – Matriz de Confusão - Random Forest

		Predito	
		Não Vitória	Vitória
Real	Não Vit.	11	41
	Vitória	11	110

Análise do Random Forest: A Figura 11 indica um padrão semelhante ao observado no MLP, porém com maior tendência à predição da classe positiva:

- Maior recall para vitórias (91,7%), mas menor especificidade (21,2%)
- Aumento no número de falsos positivos em relação ao MLP

Implicações Práticas: Conforme ilustrado pelas Figuras 10 e 11, em aplicações reais, um modelo com maior taxa de falsos positivos (predizer vitória quando ocorre não vitória) pode ser preferível a falsos negativos, pois subestimar adversários tende a ser mais custoso do ponto de vista tático do que superestimá-los.

6.1.4 Análise de Importância de Features

A interpretabilidade dos modelos foi investigada através da análise de importância de ***features*** no ***Random Forest***, revelando os fatores mais determinantes para a predição. A Tabela 10 (Tabela 10) sintetiza a importância agregada por categoria de atributos, enquanto a lista a seguir apresenta as **10 features individuais mais relevantes** segundo o modelo.

Top 10 Features Mais Importantes:

1. **mando_time** (0.0847) - Mando de campo (casa/fora)
2. **player_3_crossing** (0.0156) - Cruzamento do jogador 3
3. **player_2_long_passing** (0.0143) - Passe longo do jogador 2
4. **player_5_ball_control** (0.0128) - Controle de bola do jogador 5

5. **player_1_gk_positioning** (0.0121) - Posicionamento do goleiro
6. **player_4_finishing** (0.0115) - Finalização do jogador 4
7. **player_7_dribbling** (0.0109) - Drible do jogador 7
8. **player_6_marking** (0.0102) - Marcação do jogador 6
9. **player_8_stamina** (0.0098) - Resistência do jogador 8
10. **player_9_reactions** (0.0094) - Reações do jogador 9

Fator Casa (Dominante): A variável `mando_time` consolidou-se como a **feature individual mais importante** (8,47% da importância total), validando a ampla literatura que identifica o mando de campo como preditor crítico em esportes coletivos. Este resultado corrobora estudos prévios sobre *home advantage* no futebol.

Atributos Técnicos dos Jogadores: As nove features seguintes são todas atributos individuais de jogadores, demonstrando que:

- As habilidades técnicas extraídas do FIFA possuem **poder preditivo real** para resultados de partidas
- Diferentes posições contribuem de forma balanceada (defesa, meio-campo, ataque)
- Não há dependência excessiva de um único jogador "estrela"

Tabela 10 – Análise de importância por categoria de atributos

Categoria	Importância Total	Atributo Mais Relevante
Ofensivo	0.2847	Finishing (0.0115)
Técnico	0.2631	Ball Control (0.0128)
Físico	0.1925	Stamina (0.0098)
Defensivo	0.1743	Marking (0.0102)

Conclusão de Importância: A distribuição equilibrada entre categorias sugere que o **sucesso no futebol é multifatorial**, exigindo qualidade técnica, física e tática balanceadas. A ausência de features com importância extremamente dominante (>15%) indica que o modelo considera múltiplos aspectos do jogo.

6.1.5 Análise Temporal: Evolução do Desempenho por Temporada

Uma análise incremental foi conduzida, treinando o modelo Random Forest sequencialmente com dados de temporadas anteriores e testando na temporada seguinte. A Figura 12 ilustra

a evolução da acurácia e das métricas ao longo do tempo e a Tabela 11 mostra o resumo dos resultados.

Figura 12 – Evolução temporal: Acurácia por temporada, relação com tamanho do treino e disparidade de desempenho Casa vs. Fora.

Tabela 11 – Desempenho temporal incremental (Random Forest)

Temp. Teste	Part. Treino	Acc Geral	Acc Casa	Acc Fora	F1-Score
2017	127	62,5%	68,2%	55,3%	71,2%
2018	254	65,8%	72,1%	58,4%	74,8%
2019	381	68,3%	75,6%	60,7%	77,5%
2020	508	70,1%	78,3%	61,9%	79,2%
2021	635	71,4%	79,7%	63,1%	80,6%
Média	-	**67,6%**	**74,8%**	**59,9%**	**76,7%**

Tendência de Melhoria: Observa-se uma **tendência crescente de acurácia** conforme mais dados históricos são incorporados ao treinamento, variando de 62,5% (2017) para 71,4% (2021). Este padrão valida a abordagem de aprendizado incremental e sugere que modelos se beneficiam de histórico extenso.

Disparidade Casa vs Fora:

- **Acurácia Média Casa:** 74,8%
- **Acurácia Média Fora:** 59,9%

O modelo demonstra desempenho superior em jogos em casa, onde os resultados tendem a ser mais consistentes (maior probabilidade de vitória), enquanto jogos fora de casa introduzem maior variância e imprevisibilidade.

7
Conclusão

A análise consolidada dos resultados deste trabalho demonstra que a predição de resultados de partidas de futebol profissional pode ser realizada de forma eficaz a partir de atributos individuais de jogadores titulares, mesmo quando tais atributos são extraídos de bases de dados virtuais. A abordagem proposta foi validada por meio de um estudo de caso envolvendo 864 partidas do FC Barcelona no período de 2009 a 2026, o que permitiu verificar, em um cenário realista, que informações técnicas individuais carregam sinal preditivo relevante para o desempenho coletivo.

Além dos resultados quantitativos obtidos, os experimentos conduzidos ao longo deste trabalho indicam que a pipeline de modelagem proposta não é intrinsecamente dependente do futebol, mas sim do conceito de equipes formadas por escalações titulares compostas por indivíduos com atributos mensuráveis. Dessa forma, a metodologia pode, em princípio, ser adaptada para outros esportes coletivos que compartilhem essa mesma estrutura, como basquete, vôlei, handebol ou futebol americano, desde que existam representações adequadas dos jogadores e de suas formações iniciais.

Sob essa perspectiva, a abordagem desenvolvida também se mostra promissora como ferramenta de apoio à tomada de decisão em contextos práticos de gestão esportiva. Em particular, a pipeline pode ser explorada para avaliar o *fit* de elenco, isto é, o quão bem diferentes combinações de jogadores se complementam em termos de desempenho esperado, a partir da estimativa de probabilidades de vitória. De forma análoga, torna-se possível simular o impacto de uma potencial contratação, inserindo o novo atleta em diferentes cenários de escalação e observando como isso altera as previsões do modelo. Adicionalmente, a metodologia permite testar virtualmente múltiplas configurações de escalação, fornecendo uma base quantitativa para comparar alternativas táticas antes mesmo de sua aplicação em campo.

Outro desdobramento prático relevante decorre da análise de importância de atributos realizada ao longo do trabalho. Ao identificar quais *features* exercem maior influência nas

predições, torna-se possível não apenas interpretar o modelo, mas também utilizar essas informações como subsídio para o planejamento de treinamentos. Em particular, o direcionamento de rotinas de treino para o aprimoramento dos atributos mais relevantes tende a impactar positivamente o desempenho previsto pelo modelo, potencialmente elevando a probabilidade de vitória estimada e, consequentemente, a taxa de acerto das predições. Dessa forma, a abordagem proposta não se limita à previsão de resultados, mas também pode apoiar estratégias de desenvolvimento técnico e otimização do desempenho coletivo.

7.1 Viabilidade da Predição com Atributos Individuais

Os resultados obtidos confirmam que atributos técnicos individuais, mesmo em ausência de estatísticas dinâmicas de jogo, são capazes de sustentar modelos preditivos com desempenho competitivo. A acurácia próxima a 70% posiciona o modelo no limite superior dos valores reportados na literatura em *sports analytics*, evidenciando que dados virtuais podem atuar como proxies consistentes da qualidade técnica real dos jogadores.

7.2 Superioridade de Modelos Não Lineares

A comparação entre diferentes abordagens de aprendizado de máquina indica que arquiteturas não lineares apresentam maior capacidade de capturar a complexidade inerente às interações entre jogadores em uma escalação. Em especial, modelos baseados em aprendizado profundo demonstraram desempenho superior, reforçando que a natureza multifatorial e não linear do futebol limita a eficácia de métodos estritamente lineares para esse tipo de problema.

7.3 Determinantes Preditivos do Desempenho

A análise de importância das variáveis revelou que o mando de campo constitui o fator individual mais relevante para a predição de vitórias, corroborando evidências consolidadas na literatura esportiva. Além disso, atributos técnicos distribuídos entre dimensões ofensivas, defensivas, físicas e técnicas apresentaram contribuições equilibradas, validando o caráter multifatorial do sucesso no futebol profissional.

A identificação de jogadores historicamente reconhecidos como centrais no desempenho do clube entre os mais influentes do modelo fornece validação empírica adicional, alinhando os resultados quantitativos ao conhecimento de domínio.

7.4 Recomendações Metodológicas

Com base nos achados deste estudo, destacam-se as seguintes recomendações para trabalhos similares:

1. Priorizar abordagens não lineares para modelar interações entre jogadores;
2. Adotar estratégias de agregação inteligente de atributos como forma de reduzir dimensionalidade e ruído;
3. Preservar a distribuição natural das classes quando o objetivo for refletir cenários reais de equipes dominantes;
4. Incorporar análises temporais para avaliar estabilidade e sensibilidade a mudanças estruturais.

7.5 Trabalhos Futuros

Como continuidade desta pesquisa, propõe-se a expansão do modelo para outros clubes e ligas, a incorporação de métricas dinâmicas de desempenho e a exploração de arquiteturas avançadas de aprendizado profundo. Adicionalmente, técnicas de explicabilidade podem ampliar a interpretabilidade das predições e fortalecer a aplicação prática da abordagem em contextos reais de apoio à decisão no futebol profissional.

De forma geral, este trabalho contribui para o avanço da análise preditiva esportiva ao demonstrar que atributos individuais, quando adequadamente modelados, oferecem uma base sólida e interpretável para a compreensão dos fatores associados à vitória no futebol de alto rendimento, ao mesmo tempo em que abrem espaço para aplicações mais amplas em diferentes esportes coletivos e em cenários de planejamento, simulação, otimização de escalações e desenvolvimento orientado por dados.

Referências

ABIDIN, Z. Multi-criteria decision making in football team selection: From metrics to mindset. *Sports Performance and Analytics Review*, 2021. Citado 6 vezes nas páginas 19, 20, 21, 23, 24 e 35.

BREIMAN, L. Random forests. *Machine Learning*, Springer, v. 45, n. 1, p. 5–32, 2001. Citado na página 21.

BREIMAN, L. et al. *Classification and Regression Trees*. Belmont, CA: Wadsworth International Group, 1984. Citado na página 21.

BUNKER, R. P.; THABTAH, F. A machine learning framework for sport result prediction. *Applied Computing and Informatics*, Emerald, v. 15, n. 1, p. 27–33, 2019. Citado 2 vezes nas páginas 14 e 53.

CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, Springer, v. 20, n. 3, p. 273–297, 1995. Citado na página 23.

ELO, A. E. *The Rating of Chessplayers, Past and Present*. [S.l.]: Batsford, 1978. Citado 2 vezes nas páginas 35 e 41.

GKIASTAS, V. Artificial intelligence applications in football match forecasting. *Journal of Sports Data Science*, v. 4, p. 101–117, 2022. Citado 14 vezes nas páginas 6, 14, 19, 22, 23, 24, 25, 26, 27, 28, 33, 34, 36 e 37.

HEIJBOER, T. Football match outcome prediction using machine learning techniques. *Journal of Sports Analytics*, v. 8, n. 2, p. 123–135, 2022. Citado 12 vezes nas páginas 14, 20, 22, 28, 32, 33, 34, 35, 36, 37, 38 e 41.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, MIT Press, v. 9, n. 8, p. 1735–1780, 1997. Citado na página 26.

MALIKOV, D.; KIM, S. Regularization methods for soccer performance prediction. *Artificial Intelligence in Sports*, 2024. Citado 4 vezes nas páginas 19, 20, 33 e 36.

MATANO, F.; ROSSI, L.; PAPPALARDO, L. Augmenting sports analytics with domain knowledge. *Machine Learning*, Springer, v. 107, n. 1, p. 1–23, 2018. Citado na página 41.

NOURAIE, M.; ESLAHCHI, C.; BACA, A. Predicting football match outcomes using player attributes and position suitability. *Journal of Sports Science and Technology*, 2023. Citado 4 vezes nas páginas 20, 33, 34 e 35.

PETERSEN, K. et al. Systematic mapping studies in software engineering. *Proceedings of the 12th International Conference on Evaluation and Assessment in Software Engineering (EASE)*, British Computer Society, p. 68–77, 2008. Citado na página 29.

REEP, C.; POLLARD, R. Skill and chance in ball games. *Journal of the Royal Statistical Society: Series A (General)*, Wiley, v. 134, n. 4, p. 623–629, 1971. Citado 2 vezes nas páginas 14 e 18.

REIN, R.; MEMMERT, D. Big data and tactical analysis in elite soccer: future challenges and opportunities for sports science. *SpringerPlus*, v. 5, 2016. Disponível em: <https://doi.org/10.1186/s40064-016-3108-2>. Citado na página 18.

SHIN, H.-S.; GASPARYAN, R. A novel approach for football match outcome prediction using virtual player attributes. *International Journal of Sports Science and Engineering*, v. 8, n. 2, p. 97–108, 2014. Citado 2 vezes nas páginas 38 e 41.

SJöBERG, E. Player attributes and match prediction in european soccer. *Sports Data Science*, v. 5, n. 1, p. 22–34, 2023. Citado 15 vezes nas páginas 6, 20, 21, 22, 23, 25, 26, 32, 33, 34, 35, 36, 37, 38 e 52.

TAVANA, M. et al. A fuzzy inference system with application to player selection and team formation in multi-player sports. *Sport Management Review*, Elsevier, v. 16, n. 1, p. 97–110, 2013. Citado na página 19.

Apêndices

APÊNDICE A – Códigos completos do treinamento dos modelos

Este apêndice reúne os trechos de implementação completos referentes ao treinamento dos modelos avaliados no Capítulo 5. Esses códigos foram movidos para o apêndice por serem extensos e repetitivos, diferindo principalmente pela escolha do estimador e seus hiperparâmetros, enquanto o protocolo experimental (pré-processamento, divisão dos dados e métricas) permanece o mesmo.

A.1 Random Forest

Código 14 – Treinamento do modelo Random Forest

```
rf = RandomForestClassifier(
    n_estimators=200,
    max_depth=20,
    min_samples_split=10,
    min_samples_leaf=4,
    random_state=RANDOM_STATE,
    class_weight='balanced',
    n_jobs=-1
)
rf.fit(X_train_final, y_train_final)
```

A.2 Gradient Boosting

Código 15 – Treinamento do modelo Gradient Boosting

```
gb = GradientBoostingClassifier(
    n_estimators=200,
    learning_rate=0.1,
    max_depth=5,
    random_state=RANDOM_STATE
)
gb.fit(X_train_final, y_train_final)
```

A.3 SVM

Código 16 – Treinamento do modelo SVM com kernel RBF

```
svm = SVC(
    kernel='rbf',
    C=1.0,
    gamma='scale',
    random_state=RANDOM_STATE,
    class_weight='balanced',
    probability=True
)
svm.fit(X_train_final, y_train_final)
```

A.4 Regressão Logística

Código 17 – Treinamento do modelo de Regressão Logística

```
lr = LogisticRegression(
    max_iter=1000,
    random_state=RANDOM_STATE,
    class_weight='balanced',
    multi_class='multinomial'
)
lr.fit(X_train_final, y_train_final)
```

A.5 MLP (Rede Neural)

Código 18 – Treinamento do modelo MLP (rede neural)

```
mlp = MLPClassifier(
    hidden_layer_sizes=(128, 64, 32),
    activation='relu',
    solver='adam',
    max_iter=500,
    random_state=RANDOM_STATE,
    early_stopping=True,
    validation_fraction=0.1
)
mlp.fit(X_train_final, y_train_final)
```

A.6 XGBoost

Código 19 – Treinamento do modelo XGBoost

```
xgb_model = xgb.XGBClassifier(
    n_estimators=300,
    learning_rate=0.05,
    max_depth=7,
    subsample=0.8,
    colsample_bytree=0.8,
    random_state=RANDOM_STATE,
    eval_metric='mlogloss',
    use_label_encoder=False,
    n_jobs=-1
)
xgb_model.fit(X_train_final, y_train_final)
```

A.7 LightGBM

Código 20 – Treinamento do modelo LightGBM

```
lgb_model = lgb.LGBMClassifier(
    n_estimators=300,
    learning_rate=0.05,
    max_depth=7,
    num_leaves=31,
    subsample=0.8,
    colsample_bytree=0.8,
    random_state=RANDOM_STATE,
    n_jobs=-1,
    verbose=-1
)
lgb_model.fit(X_train_final, y_train_final)
```

A.8 CatBoost

Código 21 – Treinamento do modelo CatBoost

```
cat_model = CatBoostClassifier(
    iterations=300,
    learning_rate=0.05,
    depth=7,
    random_state=RANDOM_STATE,
    verbose=False,
    thread_count=-1
)
cat_model.fit(X_train_final, y_train_final)
```

APÊNDICE B – Experimentos comparativos de representação de features

Este apêndice contém as funções de preparação dos datasets e o protocolo de treinamento e avaliação dos experimentos comparativos descritos no Capítulo 5. A motivação é permitir reprodutibilidade sem sobrecarregar o texto principal com código de preparação e rotinas auxiliares.

B.1 Experimento 1: Atributos agregados

Código 22 – Preparação do dataset do Experimento 1 (atributos agregados)

```
def preparar_dataset_experimento1(df):
    feature_cols = []
    for i in range(1, 12):
        cols = [col for col in df.columns if f'player_{i}_' in col]
        numeric_cols = [col for col in cols
                        if '_name' not in col and '_position' not in
                           col]
        for col in numeric_cols[:10]:
            if col in df.columns:
                feature_cols.append(col)

    X = df[feature_cols].copy()
    y = df['target'].copy()
    return X, y
```

B.2 Experimento 2: Todos os atributos

Código 23 – Preparação do dataset do Experimento 2 (todos os atributos)

```
def preparar_dataset_experimento2(df):
    colunas_excluir = ['target', 'temporada', 'data', 'mando_time',
        'target_label']
    colunas_excluir += [col for col in df.columns
                        if '_name' in col or '_position' in col]

    X = df.drop(colunas_excluir, axis=1, errors='ignore')
    X = X.select_dtypes(include=[np.number])
    y = df['target'].copy()

    return X, y
```

B.3 Experimento 3: Médias por jogador

Código 24 – Preparação do dataset do Experimento 3 (médias por jogador)

```
def preparar_dataset_experimento3(df):
    features_dict = {}

    for i in range(1, 12):
        cols = [col for col in df.columns if f'player_{i}_' in col]
        numeric_cols = [col for col in cols
                        if '_name' not in col and '_position' not in
                            col
                        and df[col].dtype in ['float64', 'int64']]

        if len(numeric_cols) > 0:
            features_dict[f'player_{i}_mean'] =
                df[numeric_cols].mean(axis=1)

    X = pd.DataFrame(features_dict)
    y = df['target'].copy()

    return X, y
```

B.4 Experimento 4: Atributos-chave

Código 25 – Preparação do dataset do Experimento 4 (atributos-chave)

```
def preparar_dataset_experimento4(df):
    atributos_chave = ['gkdiving', 'gkhandling', 'crossing',
        'finishing',
                        'shortpassing', 'dribbling', 'ballcontrol',
                        'acceleration', 'sprintspeed', 'stamina',
                            'strength']

    feature_cols = []
    for i in range(1, 12):
        for attr in atributos_chave:
            col = f'player_{i}_{attr}'
            if col in df.columns:
                feature_cols.append(col)

    X = df[feature_cols].copy()
    y = df['target'].copy()

    return X, y
```

B.5 Protocolo de treinamento e avaliação dos experimentos

Código 26 – Treinamento e avaliação dos experimentos comparativos

```
def treinar_avaliar_experimento(X, y, nome_experimento):
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.20, random_state=42, stratify=y
    )

    scaler = StandardScaler()
    X_train_scaled = scaler.fit_transform(X_train.fillna(0))
    X_test_scaled = scaler.transform(X_test.fillna(0))

    X_train_balanced = X_train_scaled
    y_train_balanced = y_train

    modelos = {
        'Random Forest': RandomForestClassifier(n_estimators=200,
           random_state=42),
        'Gradient Boosting':
           GradientBoostingClassifier(n_estimators=200,
           random_state=42),
        'XGBoost': xgb.XGBClassifier(n_estimators=300,
           random_state=42),
        'LightGBM': lgb.LGBMClassifier(n_estimators=300,
           random_state=42, verbose=-1)
    }

    resultados = []

    for nome_modelo, modelo in modelos.items():
        modelo.fit(X_train_balanced, y_train_balanced)
        y_pred = modelo.predict(X_test_scaled)

        resultados.append({
            'experimento': nome_experimento,
            'modelo': nome_modelo,
            'accuracy': accuracy_score(y_test, y_pred),
            'f1': f1_score(y_test, y_pred, average='binary'),
            'num_features': X.shape[1]
        })

    return pd.DataFrame(resultados)
```

APÊNDICE C – Validação temporal incremental (*Walk-Forward*)

Este apêndice reúne o código completo do experimento temporal (*walk-forward*). A proposta é simular um cenário realista, em que o modelo é treinado apenas com temporadas passadas e testado na temporada seguinte, evitando vazamento temporal.

C.1 Função do procedimento temporal

Código 27 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 1/4

```
def treinar_avaliar_temporal(df_features, modelo_class, nome_modelo):
    colunas_excluir = ['target', 'match_id', 'temporada', 'data',
                       'mando_time', 'target_label']
    colunas_excluir += [col for col in df_features.columns
                        if '_name' in col or '_position' in col]

    feature_cols = [col for col in df_features.columns if col not in
       colunas_excluir]
    numeric_features = df_features[feature_cols].select_dtypes(
        include=[np.number]
    ).columns.tolist()

    temporadas = sorted(df_features['temporada'].unique())
    resultados_temporais = []
```

Código 28 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 2/4

```
for i, temp_teste in enumerate(temporadas[1:], 1):
    temps_treino = temporadas[:i]

    df_treino =
       df_features[df_features['temporada'].isin(temps_treino)]
    df_teste = df_features[df_features['temporada'] == temp_teste]

    X_train = df_treino[numeric_features].fillna(0)
    y_train = df_treino['target'].values
    X_test = df_teste[numeric_features].fillna(0)
    y_test = df_teste['target'].values

    scaler = StandardScaler()
    X_train_scaled = scaler.fit_transform(X_train)
    X_test_scaled = scaler.transform(X_test)

    X_train_balanced = X_train_scaled
    y_train_balanced = y_train
```

Código 29 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 3/4

```
modelo = modelo_class
modelo.fit(X_train_balanced, y_train_balanced)

y_pred = modelo.predict(X_test_scaled)

acc = accuracy_score(y_test, y_pred)
prec = precision_score(y_test, y_pred, zero_division=0)
rec = recall_score(y_test, y_pred, zero_division=0)
f1 = f1_score(y_test, y_pred, zero_division=0)

df_teste_pred = df_teste.copy()
df_teste_pred['pred'] = y_pred

mask_casa = df_teste_pred['mando_time'] == 1
acc_casa = accuracy_score(
    df_teste_pred[mask_casa]['target'],
    df_teste_pred[mask_casa]['pred']
) if mask_casa.sum() > 0 else 0.0

mask_fora = df_teste_pred['mando_time'] == 0
acc_fora = accuracy_score(
    df_teste_pred[mask_fora]['target'],
    df_teste_pred[mask_fora]['pred']
) if mask_fora.sum() > 0 else 0.0
```

Código 30 – Função de treinamento e avaliação temporal (*walk-forward*) — Parte 4/4

```
resultados_temporais.append({
    'temporada': temp_teste,
    'accuracy': acc,
    'precision': prec,
    'recall': rec,
    'f1': f1,
    'accuracy_casa': acc_casa,
    'accuracy_fora': acc_fora,
    'n_treino': len(df_treino),
    'n_teste': len(df_teste)
})

rn pd.DataFrame(resultados_temporais), modelo
```

C.2 Execução do experimento temporal

Código 31 – Execução do experimento temporal com Random Forest

```
rf_temporal = RandomForestClassifier(
    n_estimators=200,
    max_depth=20,
    class_weight='balanced',
    random_state=RANDOM_STATE,
    n_jobs=-1
)

df_resultados_rf, modelo_rf_final = treinar_avaliar_temporal(
    df_features, rf_temporal, "Random Forest"
)

print("\nResumo - Evolu  o Temporal:")
print(df_resultados_rf[['temporada', 'accuracy', 'accuracy_casa',
                        'accuracy_fora']].to_string(index=False))
```

APÊNDICE D – Importância agregada por jogador

Este apêndice apresenta o trecho de código utilizado para agregar as importâncias das features por jogador, a partir das importâncias do Random Forest. O objetivo é permitir uma interpretação mais alinhada ao domínio, relacionando a influência do modelo ao atleta (por posição na escalação) em vez de apenas às variáveis individuais.

Código 32 – Cálculo de importância agregada por jogador a partir do Random Forest

```
feature_importance_dict = dict(zip(X_train_final.columns,
                                   rf.feature_importances_))
jogador_importancia = {}

for _, row in df_features.iterrows():
    for i in range(1, 12):
        nome_col = f'player_{i}_name'

        if nome_col not in df_features.columns:
            continue

        player_name = row[nome_col]

        if pd.isna(player_name) or player_name == '':
            continue

        importancia_total = 0
        for feature_name, importance in
           feature_importance_dict.items():
            if f'player_{i}_' in feature_name:
                importancia_total += importance

        if player_name not in jogador_importancia:
            jogador_importancia[player_name] = {
                'importancia_total': 0,
                'partidas': 0,
                'vitorias': 0
            }

        jogador_importancia[player_name]['importancia_total'] +=
           importancia_total
        jogador_importancia[player_name]['partidas'] += 1
        jogador_importancia[player_name]['vitorias'] += row['target']
```